

Forschungsprojekt  
**Ausreißer-Erkennung in Zeitreihen  
mittels Graphen-basierter Algorithmen**

im Studiengang Angewandte Informatik  
der Fakultät Informationstechnik  
Wintersemester 2020/2021

Bahar Uzun

764647

Jeremy Kielman

764097

Marcus Erz

762294

**Abgabedatum:** 28. Februar 2021

**Prüferin:** Prof. Dr. rer. nat. Gabriele Gühring

---

# Kurzfassung

todo: Kurzfassung erstellen

**Schlagwörter:** Anomalie-Erkennung, Ausreißer-Erkennung, NetSimile, MIDAS, Perculation, Iso-Map Graphen-basierte Algorithmen, Zeitreihen

# Inhaltsverzeichnis

Abbildungsverzeichnis	v
Tabellenverzeichnis	vi
Listings	vii
<b>1 Einleitung</b>	<b>1</b>
1.1 Problemstellung . . . . .	1
1.2 Verwandte Arbeiten . . . . .	2
<b>2 Verwendete Daten</b>	<b>4</b>
2.1 Numenta Zeitreihen Daten . . . . .	4
2.2 Netzwerk-Datensätze . . . . .	4
<b>3 Statische Algorithmen zur Ausreißer Erkennung</b>	<b>6</b>
3.1 Umwandlung Zeitreihe in Netzwerk . . . . .	6
3.2 IsoMap Basierter Algorithmus . . . . .	7
3.2.1 IsoMap . . . . .	7
3.2.2 IsoMap zur Erkennung von Ausreisern . . . . .	7
3.2.3 Implementierung . . . . .	8
3.2.4 Ausreißererkennung in Zeitreihen . . . . .	8
3.3 Perculation basierter Algorithmus . . . . .	10
3.3.1 Implementierung . . . . .	10
3.3.2 Ausreißererkennung in Zeitreihen . . . . .	11
<b>4 Dynamische Algorithmen zur Ausreißer Erkennung</b>	<b>13</b>
4.1 Umwandlung der Daten in ein Netzwerk . . . . .	13
4.2 Netsimile . . . . .	15
4.2.1 Grundlagen . . . . .	15
4.2.2 Erweiterung des Algorithmus . . . . .	16
4.2.3 Optimierte Implementierung des Algorithmus . . . . .	22
4.3 MIDAS . . . . .	26
4.3.1 Grundlagen . . . . .	26
4.4 Ausreißer-Erkennung in Graphen . . . . .	28
4.5 Ausreißer-Erkennung in Zeitreihen . . . . .	31
<b>5 Fazit und Ausblick</b>	<b>34</b>
5.1 Fazit . . . . .	34
5.2 Ausblick . . . . .	36

A	Netsimile	37
A.1	Eindimensionales Signal ursprüngliche Version . . . . .	37
A.2	Eindimensionales Signal Optimierte Version . . . . .	37
A.3	Zweidimensionales Signal Optimierte Version . . . . .	40
B	Midas	44
C	Isomap	46
C.1	Eindimensionales Signal . . . . .	46
D	Perculation	48
D.1	Sliding Window . . . . .	48
	Literaturverzeichnis	51

# Abbildungsverzeichnis

3.1	Berechnung der Distanz zwischen zwei Punkten nach Anwendung des IsoMap Algorithmus . . . . .	7
3.2	Problem Übergänge . . . . .	9
3.3	Ablauf Perculation basierter Algorithmus . . . . .	10
3.4	Vergleich Perculation Algorithmus mit Sliding Window Verfahren und ohne Sliding Window Verfahren . . . . .	11
4.1	Umwandlung einer Zeitreihe in Netzwerk. Bei dem Netzwerk handelt es sich hier um ein Symbolbild . . . . .	13
4.2	Datensatz Midas. 1Spalte: Ursprungsknoten, 2Spalte: Zielknoten, 3Spalte: Abschnitt . . . . .	14
4.3	Vollständiger Graph mit 11 Knoten . . . . .	17
4.4	Signaturvektoren der Zeitreihe mit vollständigen Graphen . . . . .	18
4.5	Ausreißer Score der vollständigen Graphen . . . . .	19
4.6	Ausreißer Score der vollständigen Graphen mit gewichteten Kanten . . . . .	19
4.7	Ausreißer Score Enron Datensatz . . . . .	20
4.8	Darstellung der Ausreißer in Heatmaps . . . . .	21
4.9	Ausreißer Score DARPA . . . . .	22
4.10	Der Ausreißer-Score über die Zeit beim ENRON-Datensatz . . . . .	29
4.11	Die Ausreißer des SEDANSPOT-Algorithmus . . . . .	29
4.12	Der Ausreißer-Score über die Zeit beim DARPA-Datensatz . . . . .	30
4.13	MIDAS Algorithmus angewandt auf Zeitreihe mit einer erhöten Amplitude . . . . .	32
4.14	Ausreißer Erkennung in Zeitreihen MIDAS Algorithmus . . . . .	32
4.15	Ausreißer Erkennung Zeitreihen MIDAS Algorithmus Fenstergröße 110 . . . . .	33
4.16	Ausreißer Erkennung Zeitreihen MIDAS-R . . . . .	33

# Tabellenverzeichnis

3.1	IsoMap Performance . . . . .	8
3.2	Perculation Time Series Performance . . . . .	11
4.1	Ursprünglicher Netsimile Performance . . . . .	23
4.2	Parameter Netsimile Zeitreihen . . . . .	24
4.3	Netsimile Time Series Perfomance . . . . .	25
4.4	Übersicht über historische Ereignisse, die den Ausreißern zuzuordnen sind . . . . .	30
5.1	Vergleich der Algorithmen . . . . .	34
5.2	Überblick der Performanz in [min] . . . . .	35

# Listings

4.1 Gewichtung als neues Feature . . . . .	16
1	

# 1 Einleitung

Im Rahmen der Forschungsprojekt werden verschiedene Algorithmen zur Ausreißer-Erkennung in Graphen erforscht und getestet. Nachfolgend soll die Motivation hinter dieser Thematik erläutert werden.

## 1.1 Problemstellung

Eine leistungsfähige Methode Zeitreihendaten abzubilden, um Korrelationen zwischen voneinander abhängigen Datenobjekten zu erfassen, ist die Abbildung von Zeitreihendaten als Graphen. Durch diese Datenrepräsentation können Ausreißer bzw. Anomalien, vor allem in Netzwerken, schneller erkannt werden.

In der Forschung gibt es bereits viele Algorithmen zur Ausreißererkennung, die auf statische, sowie dynamische Graphen anwendbar sind. Die Erkennung der Ausreißer erfolgt mit verschiedenen Ansätzen. So gibt es Algorithmen, die die Struktur der Graphen näher betrachten, aber auch Algorithmen, die sich auf die Anzahl der Verbindungen zwischen zwei Kanten bzw. Objekten fokussieren. Nimmt man dynamische Graphen zur Untersuchung, so spielen die strukturellen Veränderungen über die Zeit, sowie die plötzlich massiv zunehmende Aktivitäten zwischen Knoten- und Kantenpaaren eine große Rolle. Darüber hinaus gibt es Ansätze zur Ausreißererkennung in sequenziellen Daten.

Allerdings gibt bisher keine Forschung von graphen-basierten Algorithmen auf traditionellen Zeitreihendaten, wie Sensordaten, die über die Zeit gesammelt werden, sondern nur über sich über die Zeit ändernden Netzwerkstrukturen.

Im Rahmen des Forschungsprojekts werden daher, die graphen-basierten Algorithmen zur Erkennung von Ausreißern in Zeitreihendaten herangezogen, um erste Erkenntnisse über die Aussagefähigkeit der Ergebnisse treffen zu können. Bei einem erfolgreichen Einsatz der Algorithmen können die Anwendungsfälle auf die Bereiche Internet of Things, Autonomes Fahren, sowie die Erkennung von Krankheiten, wie Krebs erweitert werden. Dies macht das Thema der Ausreißererkennung mittels graphen-basierter Algorithmen zu einem außerordentlich aktuellen und wichtigen Forschungsgebiet, in dem die Vorteile einer graphen-basierten Struktur auf die Zeitreihen übertragen werden.

Das Ziel der vorliegenden Arbeit setzt sich aus den folgenden Teilzielen zusammen:

1. Die Ermittlung einer Möglichkeit zur Transformation einer Zeitreihe in einen Graphen.
2. Die Anwendung der graphen-basierten Algorithmen auf Zeitreihendaten.
3. Der Vergleich verschiedener Algorithmen und deren Eignung Ausreißer zu erkennen.

## 1.2 Verwandte Arbeiten

In diesem Abschnitt werden Ansätze zur Erkennung von Ausreißern in statischen und dynamischen Graphen vorgestellt, die im Rahmen des Forschungsprojekts zur Erreichung der Forschungsziele herangezogen werden.

Die **Ausreißer-Erkennung in statischen Graphen** kann hinsichtlich ihrer Ausreißerkategorien unterteilt werden. So ergibt sich die nachfolgende Taxonomie.

**Struktur-basierter Ansatz:** Mithilfe der Darstellung von Knoten und Kanten in einem Ego-Netzwerk werden bei [?] die zugehörigen Eigenschaften, wie die Anzahl der Knoten und Kanten extrahiert. Im Anschluss identifiziert dieser Algorithmus diejenigen Knoten und Kanten, die sich strukturell stark vom restlichen Ego-Netzwerk unterscheiden.

**Clustering-basierter Ansatz:** Bei [?] werden zwei Knoten und die Überschneidung ihrer Nachbarknoten gegenübergestellt. So wird die Annahme getroffen, dass Knoten, die sehr wenige Nachbarn, im Vergleich zum Rest der Knoten in Ihrer Umgebung haben, Ausreißer sind.

**IsoMap-basierter Ansatz:** Durch die Dimensionsreduktion mithilfe des [?] gehen Informationen über Ausreißer verloren. Bei dem Versuch der Rekonstruktion können diese Informationen nicht wiederhergestellt werden und der Ausreißer wird sichtbar.

**Kanten-basierter Ansatz:** Bei [?] werden aus einem Graphen schrittweise die Kanten mit den höchsten Gewichten entfernt. Dadurch werden Ausreißer vom Rest des Netzwerks separiert. Die Annahme ist, dass Ausreißer-knoten höhere Kantengewichte zu ihren Nachbarn haben. Der [?] iteriert der Algorithmus zufällig über das Netzwerk. Dabei wird festgehalten wie oft ein Knoten besucht wurde. Ausreißer-Knoten werden dabei besonders selten besucht und können somit identifiziert werden.

**todo: hier geht es weiter** Die **Anomalieerkennung in Edge Streams** verwendet als Eingabe einen Fluss von Kanten über die Zeit. Sie werden nach der Art der erkannten Anomalie kategorisiert:

**Erkennung anomaler Knoten:** Mithilfe eines Edge Streams erkennt [18] Knoten, deren Egonetze sich plötzlich und signifikant ändern.

**Erkennung anomaler Subgraphen:** Mithilfe eines Edge Streams identifiziert [15] dichte Teilgraphen, die innerhalb einer kurzen Zeit entstehen.

**Anomale Kantenerkennung:** [14] konzentriert sich auf spärlich verbundene Teile eines Graphen, während [7] Kantenanomalien basierend auf dem Auftreten von Kanten, bevorzugter Anhaftung und gegenseitigen Nachbarn identifiziert.

## Related Work für Netsimile:

Graph isomorphism M.-L. Fernandez and G. Valiente, A graph distance metric combining maximum common subgraph and minimum common supergraph [8]

Iterative Methoden Zager et.al [19]

Feature Extraction Li et al. – global feature extraction [10]

Die **Ausreißer Erkennung in Zeitreihen und Sequenziellen Daten** wurde bereits in vielen Literaturquellen diskutiert.

Netzwerk basierter Ansatz zur Erkennung von Ausreißern in Sequenziellen Daten[13]: Der genannte Algorithmus wandelt Sequenziellen Daten in ein Netzwerk um. Dabei wird die Euklidischen Distanz genutzt um die Kantengewichte zu berechnen. Anschließend werden die Knoten mithilfe des Minimum Spanning Tree Algorithmus geclustered. Um hierraus Ausreißer zu abzuleiten wird ein Voting Scheme verwendet. Der vorgestellte Algorithmus wurde genutzt um Ausreißer in Wetter Daten sowie Aktienkursen zu identifizieren.

Ein robuster graphbasierter Algorithmus zur Erkennung und Charakterisierung von Anomalien in verrauchten multivariaten Zeitreihen: In diesem Paper [5] wird ein Algorithmus vorgestellt, der dazu in der Lage ist Ausreißer in Multivariaten Zeitreihen zu erkennen. Die multivariate Zeitreihe wird dabei über ein Distanzmaß in ein Netzwerk umgewandelt. Auf dem Netzwerk wird anschließend ein Random Walk Algorithmus ausgeführt. Daraufhin werden Knoten die besonders selten besucht wurden als Ausreißer markiert.

Überblicksartikel über die Ausreißer Erkennung in Diskreten Sequenzen: In [4] werden verschiedene Methoden vorgestellt, wie Ausreißer in Sequenzen erkannt werden können. Es wird dabei, auch auf die Ausreißer Erkennung in Zeitreihen eingegangen. Die vorgestellten Algorithmen werden in drei Kategorien untergliedert. 1:Erkennung abnormaler Sequenzen in Bezug auf eine Datenbank normaler Sequenzen 2: Erkennung einer abnormalen Untersequenz innerhalb einer langen Sequenz. 3: Erkennung eines Musters in einer Sequenz deren Auftrittshäufigkeit anomal ist.

Neuronale Netze zur Ausreißer Erkennung: Die Verwendung von Neuronalen Netzen zur Erkennung von Ausreißern wird immer beliebter. Beispielsweise wurde in [9] ein Repli-cator Neuronales Netz, einerseits genutzt um Störungen in einem Netzwerk zu erkennen. Des weiteren wurde das Neuronale Netz verwendet um Ausreißer in einem Brustkrebs Datensatz zu identifizieren. Neuronale Netze wurden ebenso dazu eingesetzt um Ausreißer in Zeitreihen zu finden [12] . Ein Vorteil dieses Ansatzes ist, das Ausreißer online entdeckt werden können. Das Neuronale Netz wird hierbei dazu genutzt den nächsten Wert einer Zeitreihe zu schätzen. Die Differenz zwischen der Vorhersage und dem tatsächlich auftretenden Wert wird als Ausreißer Score verwendet.

## 2 Verwendete Daten

### 2.1 Numenta Zeitreihen Daten

Bei diesem Datensatz handelt es sich um künstlich erzeugte Zeitreihen der Numenta Gruppe. Diese Zeitreihen enthalten unterschiedliche Arten von Ausreißern. Dadurch kann untersucht werden für welche Ausreißer Typen die Algorithmen gut geeignet sind. Für die Tests auf multivariaten Zeitreihen wurden neue Zeitreihen erzeugt. Dabei wurde für die erste Dimension eine Zeitreihe der Numenta Gruppe verwendet. Für weitere Dimensionen wurde auf eine Zeitreihe ohne Ausreißer zurück gegriffen.

todo: vielleicht noch Bild von einer Zeitreihe einfügen. todo: Vielleicht Numenta verlinken

### 2.2 Netzwerk-Datensätze

Im Forschungsgebiet der Ausreißer-Erkennung in Graphen herrscht eine starke Konkurrenz unter den wenigen Forschern. Aus diesem Grund finden sich zum Großteil der veröffentlichten Paper, sowie Code, keine gelabelten Datensätze. Diese werden, um den eigenen Vorteil nicht zu verlieren, zurückgehalten für die eigene Forschung. todo: Paper finden und Quelle einfügen zu dieser Problematik

Im Rahmen des Forschungsprojekts konnten zwei Datensätze verwendet werden deren Ausreißer in unterschiedlichen Formen deklariert wurden. Diese Datensätze werden im Folgenden vorgestellt.

#### Enron

Der Enron Datensatz enthält die intern versendeten E-Mail Daten von rund 150 Mitarbeitern der Firma Enron. Die Daten wurden von der Federal Energy Regulatory Commission offengelegt. Enthalten sind ca. 50.000 E-Mail-Nachrichten. Für den Algorithmus wird lediglich der Zeitpunkt, an dem eine E-Mail versendet wird, sowie die Sender und Empfänger festgehalten.

Die Messung der Ausreißer erfolgt in zwei Schritten. Zum einen werden Erkenntnisse aus dem Schaubild des SEDANSPOT-Algorithmus gewonnen todo: Quelle eingeben. Im nächsten Schritt wird die selbe Vorgehensweise wie aus dem SEDANSPOT-Paper gewählt und die ENRON Timeline todo: Quelle einfügen zur Erhebung von möglichen Auswirkungen für die Ausreißer hinzugezogen.

## DARPA

Der DARPA-Datensatz [11] beinhaltet 4.5 Millionen IP zu IP Kommunikationen zwischen 9.4 Tausend Quell-IP's und 23.3 Tausend Ziel-IP's über einen Zeitraum von 87.7 Tausend Minuten. Jede Kommunikation ist eine gerichtete Kante von der Quell-IP zur Ziel-IP in einem Zeitpunkt. Eine vierte Spalte des Datensatzes ist verfügbar, in der ein *label* enthalten bzw. ein Angriff gekennzeichnet ist. Der DARPA-Datensatz besteht zu über 60% aus Ausreißern. **todo: Quelle zum Datensatz einfügen**

# 3 Statische Algorithmen zur Ausreißer Erkennung

In diesem Kapitel werden zunächst zwei statische Algorithmen zur Ausreißer Erkennung auf unterschiedlichen Datentypen (z.B. Videos, Bilder, Netzwerke) vorgestellt. Hierbei handelt es sich um ein auf Percolation basierender Algorithmus und ein auf IsoMap basierender Algorithmus. Statische Algorithmen kennzeichnen, dass sie nicht mit Daten umgehen können, welche kontinuierlich an sie übergeben werden. Damit die Algorithmen anwendbar sind müssen die Daten vollständig und abgeschlossen vorliegen. Eines unserer Hauptziele des Forschungsprojektes war die Ausreißer Erkennung in Zeitreihen, aus diesem Grund untersuchten wir die Algorithmen auf ihre Fähigkeit Ausreißer in Zeitreihen zu finden. In [Kap. 3.2](#) wird der Iso Map basierte Algorithmus vorgestellt in [Kap. 3.3](#) wird der Percolation basierte Algorithmus vorgestellt.

Beide Algorithmen liefern lediglich einen Ausreißer Score zurück. Um zu bestimmen inwiefern ein Element konkret ein Ausreißer ist, wird zunächst den Mittelwert und die Standardabweichung des Outlier Scores berechnet. Falls ein Element in Abhängigkeit von der Standardabweichung sehr stark vom Mittelwert abweicht wird das Element als Ausreißer klassifiziert.

## 3.1 Umwandlung Zeitreihe in Netzwerk

Damit sowohl der auf Percolation basierende Algorithmus wie auch der auf Iso Map basierende Algorithmus angewandt werden können, müssen die Daten zunächst in ein einheitliches Format überführt werden. Dazu müssen die unterschiedlichen Daten in ein Netzwerk umgewandelt werden. Hierzu ist erforderlich, dass eine Distanz zwischen unterschiedlichen Elementen des Datensatzes berechnet werden kann [vgl. [1](#), S. 2]. Der Algorithmus kann auf allen Daten angewandt werden, welche diese Voraussetzung erfüllen. Nachfolgend wird exemplarisch beschrieben wie die Transformation für eine Zeitreihe funktionieren kann.

Für die Transformation der Zeitreihe, muss zunächst die Distanz zwischen den einzelnen Elementen (Zeitpunkten) der Zeitreihe berechnet werden. Hierzu wird das Distanzmaß aus [Gl. 3.1](#) genutzt.

$$D_{ij} = \left( \sum_k |v_k^i - v_k^j|^p \right)^{1/p} \quad (3.1)$$

Insofern in die Gleichung für  $p = 2$  eingesetzt wird, handelt es sich hierbei um die euklidische Distanz. Die mit [Gl. 3.1](#) berechneten Distanzen bilden die Kantengewichte in dem neu erstellten Netzwerk. Das neue Netzwerk ist hierbei Fully Connected. Das heißt jeder Knoten ist mit allen

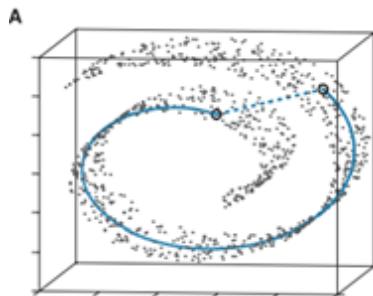
anderen Knoten über eine Kante verknüpft. Die Knoten des Netzwerks repräsentieren die einzelnen Elemente(Zeitpunkte) der zeit reihe. [vgl. 1, S. 2]. Es können mit dieser Vorgehensweise auch multivariate Zeitreihen in ein Netzwerk transformiert werden.

## 3.2 IsoMap Basierter Algorithmus

Der Ansatz dieses Algorithmus ist, dass Informationen über Ausreißer bei der Reduzierung der Dimensionalität mit dem IsoMap verloren gehen. Insofern versucht wird, die Informationen zu rekonstruieren und mit der ursprünglichen Matrix vergleicht, können große Abweichungen bei Ausreißer Elementen festgestellt werden [vgl. 1, S. 3]. In Kap. 3.2.1 wird zunächst erklärt wie der Iso Map Algorithmus eine Reduzierung der Dimensionalität durchführt. Anschließend werden in Kap. 3.2.2 die zusätzlichen Schritte erläutert, welche notwendig sind um Ausreißer mithilfe des IsoMap Algorithmus zu erkennen.

### 3.2.1 IsoMap

Beim IsoMap handelt es sich um einen Algorithmus zur nichtlinearen Dimensionsreduktion. Zunächst werden beim IsoMap Algorithmus die Nachbarn eines jeden Punktes(Knoten) über K-Nearest Neighbor bestimmt. Anschließend wird jeder Punkt mit den gefundenen Nachbarn verknüpft, wodurch ein neuer Körper(Netzwerk) entsteht. Daraufhin wird eine neue Distanzmatrix auf dem entstandenen Körper berechnet, indem die kürzeste Distanz zwischen allen Punkten auf dem Körper berechnet wird. Diese Matrix kann auch als geodätische Distanzmatrix  $D_G$  bezeichnet werden. Die eigentliche Dimensionsreduktion wird anschließend über die Eigenvektoren und Eigenwerte der Matrix  $D_G$  durchgeführt. Das Ergebnis der Dimensionsreduktion ist eine neue Menge an Features für jedes Element  $V^i = v_1^i \dots v_r^i$  des ursprünglichen Datensatzes. Durch das Erzeugen der Matrix  $D_G$  wird erreicht, das nichtlineare Zusammenhänge bei der Dimensionsreduktion erhalten bleiben. [vgl. 16, S. 3-4].



**Abb. 3.1:** Berechnung der Distanz zwischen zwei Punkten nach Anwendung des IsoMap Algorithmus

### 3.2.2 IsoMap zur Erkennung von Ausreisern

Mithilfe des IsoMap Algorithmus wurden für jedes Element neue Features ( $V^i = v_1^i \dots v_r^i$ ) berechnet. Im nächsten Schritt wird versucht aus diesen Featurn die ursprüngliche Distanzmatrix zu

rekonstruieren. Dazu wird aus den Featuren  $V^i$  unter Verwendung von Gl. 3.1 eine neue Distanzmatrix  $\hat{D}$  berechnet. Nun können die Matrizen  $D_G$  und  $\hat{D}$  miteinander verglichen werden. Hierzu muss die Pearson Korrelation zwischen den jeweiligen Spalten der Matrizen berechnet werden. Für Ausreißer wird erwartet, dass die Korrelation sehr niedrig ist, da Informationen über sie bei der Reduktion verloren gehen [vgl. 1, S. 3].

### 3.2.3 Implementierung

Für den Iso Map Algorithmus stellt SciKit Learn eine sehr gute Implementierung zur Verfügung. Diese Implementierung konnten wir gut in unseren Algorithmus integrieren. Es musste lediglich geändert werden, dass auf die Matrix  $D_G$  zugegriffen werden kann. Dies ist standardmäßig nicht der Fall. Für die Implementierung der weiteren Funktionalität wurde auf Python/Numpy zurückgegriffen.

### 3.2.4 Ausreißererkennung in Zeitreihen

**todo:** Erklären welche Zeitreihen verwendet wurden. Hab ich so ein bisschen gemacht vielleicht das noch in extra Kapitel machen.

Für die durchgeföhrten Tests wurden die Zeitreihen aus ... verwendet. Um zu bewerten wie gut der Algorithmus funktioniert, wurde ein Punktesystem eingeföhrt. In dem Punktesystem konnten maximal vier Sterne erreicht werden. Das bedeutet Ausreißer sehr gut erkannt. Null Sterne hingegen bedeuten Ausreißer überhaupt nicht erkannt. Der IsoMap Algorithmus liefert eher schwache Ergebnisse bei der Erkennung von Ausreißern in Zeitreihen. Hauptproblem hierbei ist, dass starke Anstiege, bei welchen es sich nicht um Ausreißer handelt, fälschlicherweise zu einem starken Anstieg des Ausreißer Scores führen (vgl. Abb. 3.2 mit Pfeil markierte stellen). Dies kann, je nach Threshold, zu einer hohen Quote an falsch positiven Klassifizierungen führen. Aus diesem Grund können die tatsächlichen Ausreißer nicht eindeutig identifiziert werden. Eine

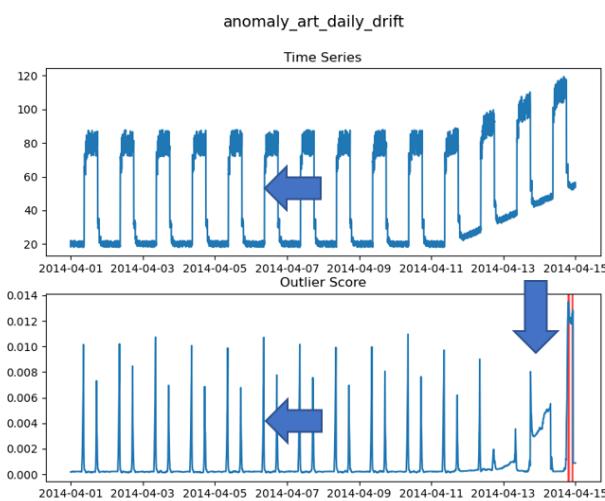
Ausreißer Typ	Datei Name	1D
Einzelne Peaks	anomaly-art-daily-peaks	*
Zunahme an Rauschen	anomaly-art-daily-increase-noise	**
Signal Drift	anomaly-art-daily-drift	**
Kontinuierliche Zunahme der Amplitude	art-daily-amp-rise	**
Zyklus mit höherer Amplitude	art-daily-jumpsup	*
Zyklus mit geringerer Amplitude	art-daily-jumpsdown	**
Zyklus-Aussetzer	art-daily-flatmiddle	*
Signal-Aussetzer	art-daily-nojump	-
Frequenzänderung	anomaly-art-daily-sequence-change	-

**Tab. 3.1:** IsoMap Performance

Ähnliche Problematik trat in [17] bei der Verwendung des Random Walk Algorithmus auf. Das Problem konnte hierbei gelöst werden, indem vor der Anwendung des Algorithmus, eine Glättung der Zeitreihe durchgeführt wurde. Dadurch werden abrupte Übergänge in der Zeitreihe abgemildert und deshalb nicht mehr als Ausreißer erkannt [vgl. 17, S. 31,36]. Dies könnte ein möglicher Ansatz sein um zukünftig bessere Ergebnisse zu erzielen.

Des Weiteren ist zu erkennen, dass der Algorithmus für einige Ausreißer Typen nicht geeignet ist, hierzu gehören Signal Aussetzer und Frequenzänderungen. Bei diesen Ausreißer Typen treten keinerlei unüblichen Werte auf, sondern es kommt zu Änderungen in der Saisonalität der Zeitreihe.

todo: Wie genau bezieht man sich auf seine eigene Ausarbeitung



**Abb. 3.2:** Problem Übergänge

### 3.3 Perculation basierter Algorithmus

Bei diesem Algorithmus werden schrittweise die Kanten mit den höchsten Gewichten aus der mit Gl. 3.1 erzeugten Distanzmatrix  $D_{ij}$  entfernt. Ziel dieses Prozesses ist es Ausreißer vom restlichen Teil des Netzwerks zu trennen. Dabei kann davon ausgegangen werden, dass Ausreißer höhere Kantengewichte zu ihren Nachbarn aufweisen und deshalb schneller separiert werden. Sobald ein Knoten komplett separiert ist, wird ihm ein Ausreißer Score zugeordnet. Der Wert des Ausreißer Scores wird über die zuletzt entfernte Kante des Knoten definiert. Dadurch erhalten früher separierte Knoten höhere Ausreißer Scores als später separierte Knoten [vgl. 1, S. 3].



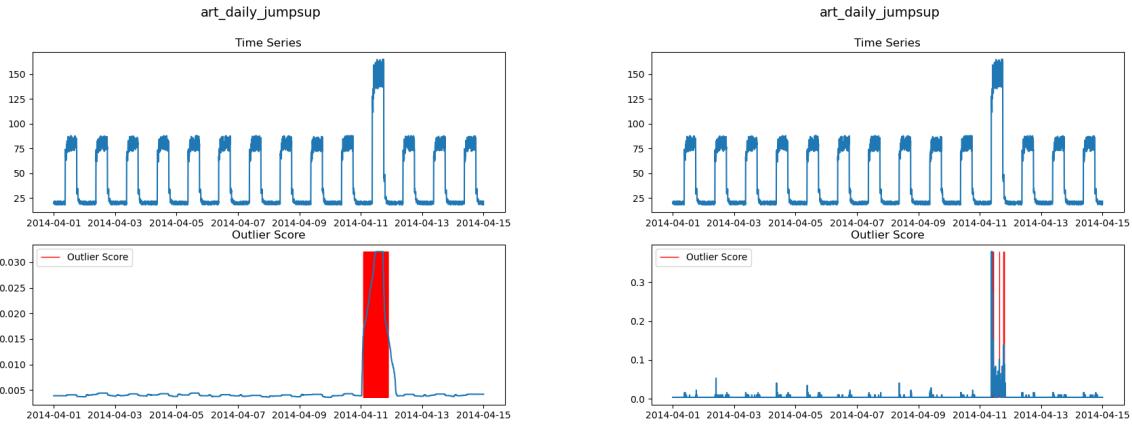
**Abb. 3.3:** Ablauf Perculation basierter Algorithmus

#### 3.3.1 Implementierung

Für die Implementierung des Perculation-basierten Algorithmus wurde genauso wie in Kap. 3.2.3, Python/Numpy verwendet. Bei der Implementierung eines Prototypen des Algorithmus konnte festgestellt werden, dass die Laufzeit des Algorithmus sehr langsam ist. Aus diesem Grund wurden einige Veränderungen an dem Algorithmus vorgenommen um die Performance zu verbessern. Dazu gehörte, dass nicht einzelne Kanten, sondern Gruppen an Kanten aus dem Netzwerk entfernt werden. Der Vorteil dieser Modifikation ist, dass seltener überprüft werden muss ob ein Knoten weiterhin mit den Rest des Netzwerks verbunden ist. Eine weitere Verbesserung, die eingeführt wurde, ist die Verankerung eines Abbruchkriteriums. Dabei wird der Algorithmus angehalten sobald eine bestimmte Menge an Kanten aus dem Netzwerk entfernt wurde. Da der Algorithmus nicht alle Berechnungen ausführen muss, kann damit eine Optimierung der Laufzeit erreicht werden. Weiterhin konnte festgestellt werden, dass diese Veränderung keinen Einfluss auf die Qualität der Ausreißer Erkennung hat, da Ausreißer lediglich zu Beginn des Algorithmus gefunden werden. Ein weiteres Problem des Ursprünglichen Algorithmus war, dass bei aufeinanderfolgenden Elementen der Zeitreihe teilweise starke Schwankungen im Ausreißer Score auftraten (vgl. Abb. 3.4). Aus diesem Grund konnten Ausreißer, welche sich über mehrere Zeitpunkte hinweg erstrecken nicht komplett erkannt werden. Um die Schwankungen im Ausreißer Score abzumildern, wurde dieser geglättet. Dazu wurde der Gleitende Mittelwert des Ausreißer Scores berechnet. In ?? ist exemplarisch die Formel für einen Gleitenden Mittelwert der Ordnung drei dargestellt. In Abb. 3.4 ist zu sehen wie sich der Ausreißer Score durch das Glätten verändert.

$$m_{\text{MA}}^{(3)}(t) = \frac{1}{3} (x(t-1) + x(t) + x(t+1)) \quad (3.2)$$

todo: Das Verfahren zur Glättung das hier eingesetzt wird heißt gleitender Mittelwert. Vielleicht FOrmel davon einfügen und dan noch passende Quelle finden todo: Parameter noch erklären



**Abb. 3.4:** Vergleich Perculation Algorithmus mit Sliding Window Verfahren und ohne Sliding Window Verfahren

### 3.3.2 Ausreißererkennung in Zeitreihen

Es konnte festgestellt werden, dass der Perculation basierte Algorithmus, viele Ausreißer Typen sehr gut erkennt. Ob Ausreißer in einer Zeitreihe mit einzelnen Peaks gefunden werden, hängt davon ab, ob der Ausreißer Score geglättet wird. Insofern keine Glättung des Ausreißer Scores durchgeführt wird, können einzelne Peaks gefunden werden. Denn durch die Glättung der Zeitreihe verschwinden die Ausschläge im Ausreißer Score. Es muss also in Abhängigkeit des Anwendungsfalles entschieden werden ob der Ausreißer Score geglättet wird. Dabei wäre ebenfalls

Ausreißer Typ	Datei Name	1D
Einzelne Peaks	anomaly-art-daily-peaks	*
Zunahme an Rauschen	anomaly-art-daily-increase-noise	****
Signal Drift	anomaly-art-daily-drift	***
Kontinuierliche Zunahme der Amplitude	art-daily-amp-rise	***
Zyklus mit höherer Amplitude	art-daily-jumpsup	****
Zyklus mit geringerer Amplitude	art-daily-jumpsdown	****
Zyklus-Aussetzer	art-daily-flatmiddle	****
Signal-Aussetzer	art-daily-nojump	-
Frequenzänderung	anomaly-art-daily-sequence-change	-

**Tab. 3.2:** Perculation Time Series Performance

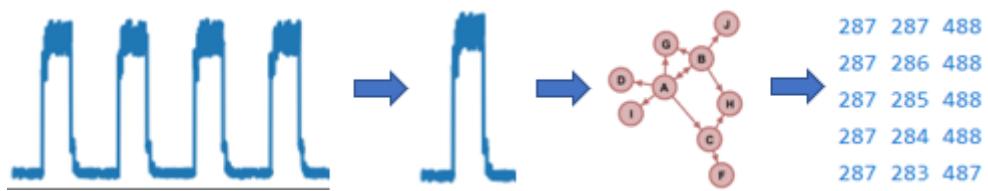
denkbar, das beide Varianten zur Erkennung von Ausreißern verwendet werden. Der Perculation basierte Algorithmus ist genauso wie der Iso Map basierte Algorithmus (vgl. Kap. 3.2.4) nicht dazu im Stande Ausreißer in Zeitreihen mit Signal Aussetzer und Frequenzänderung zu erkennen.

# 4 Dynamische Algorithmen zur Ausreißer Erkennung

In diesem Kapitel werden zwei Algorithmen zur dynamischen Erkennung von Ausreißern vorgestellt. Hierbei handelt es sich um den Netsimile (vgl. Kap. 4.2) und den MIDAS (vgl. Kap. 4.3) Algorithmus. Dynamische Algorithmen können im Gegensatz zu statischen Algorithmen, Ausreißer in Echtzeitdaten finden. Dies kann in der Praxis sehr wichtig sein, da Ausreißer möglichst schnell gefunden werden müssen um finanzielle Schäden abzuwenden. Die dynamischen Algorithmen wurden genauso wie die statischen Algorithmen, von uns so gestaltet, das sie mit unterschiedlichen Daten Typen umgehen können. In unseren Experimenten wurden die Algorithmen auf Netzwerk- und Zeitreihen Daten angewandt.

## 4.1 Umwandlung der Daten in ein Netzwerk

Dieser Schritt muss durchgeführt werden bevor die Algorithmen angewandt werden können. Dabei funktioniert die Umwandlung der Daten genauso wie für statische Algorithmen (vgl. Kap. 3.1). Einziger Unterschied hierbei ist, das jeweils kleine Abschnitte der Daten in Netzwerke umgewandelt werden. Um dies zu veranschaulichen ein kurzes Beispiel: Ein Temperatur Sensor liefert jede Sekunde einen Wert. Sobald 100 Werte des Sensors eingegangen sind erfolgt die Umwandlung dieser Daten in ein Netzwerk unter Verwendung von Gl. 3.1. Dieser Vorgang wiederholt sich anschließend immer wieder. Der Wert für die Länge der Abschnitte ist hierbei frei wählbar und kann als Parameter übergeben werden. Insofern die Zeitreihe eine Saisonalität besitzt, bietet es sich an diese für die Länge der Abschnitte zu verwenden. In einem letzten Schritt werden anschließend die Netzwerkdaten in eine Datei geschrieben. Dieser Schritt ist aufgrund der Art und Weise, wie die Algorithmen implementiert sind notwendig. In Kap. 3.1 ist graphisch dargestellt wie die Umwandlung der Daten in ein Netzwerk funktioniert.



**Abb. 4.1:** Umwandlung einer Zeitreihe in Netzwerk. Bei dem Netzwerk handelt es sich hier um ein Symbolbild.

Die verschiedenen Algorithmen erfordern unterschiedliche Übergabeformate. Aus diesem Grund werden anschließend kurz die Besonderheiten erklärt, auf welche dabei geachtet werden muss.

**Netsimile:** Das Übergabeformat für den Netsimile Algorithmus ist in Abb. 4.1 ganz rechts dargestellt. Jede Zeile stellt hierbei eine Kante des Netzwerks dar. Bei der ersten Spalte handelt

es sich um den Ursprungsknoten der Kante, bei der zweiten Spalte um den Zielknoten und bei der letzten Spalte um die Gewichtung.

**MIDAS:** Beim MIDAS Algorithmus ist es nicht möglich die Gewichtung der Kanten direkt an den Algorithmus zu übergeben. Es ist jedoch möglich die Gewichtung der Kanten indirekt an den Algorithmus zu übergeben. Dazu wird die gleiche Kante mehrmals in Abhängigkeit der Gewichtung an den Algorithmus übergeben. In Abb. 4.2 ist ein kleiner Ausschnitt einer Datei für den MIDAS dargestellt.

```
248 259 7  
248 259 7  
248 259 7  
248 259 7
```

**Abb. 4.2:** Datensatz Midas. 1Spalte: Ursprungsknoten, 2Spalte: Zielknoten, 3Spalte: Abschnitt

**MIDAS-R:** Die Berechnungen für den MIDAS-R Algorithmus sind im Verhältnis zum MIDAS Algorithmus umfangreicher. Insofern für den MIDAS-R Algorithmus die gleichen Daten verwendet werden wie für den MIDAS Algorithmus, benötigen die Berechnungen sehr lange. Aus diesem Grund wurde eine Hauptkomponenten Zerlegung durchgeführt, um die Größe der Adjazenzmatrix zu verringert. Es entsteht ein kleineres Netzwerk, welches an den MIDAS-R Algorithmus übergeben werden kann.

todo: Midas R liefert eigentlich mehrere Ausreißer Scores es wäre vielleicht interessant diese einzeln zu betrachten und nicht zusammenaddiert.

## 4.2 Netsimile

### 4.2.1 Grundlagen

Netsimile ist ein skalierbarer Algorithmus zur Erkennung von Ähnlichkeiten, sowie Anomalien in Netzwerken unterschiedlicher Größen. Hierfür wird der Datensatz in gleich große Zeitintervalle unterteilt, um die daraus resultierenden Graphen auf unterschiedliche Merkmale zu untersuchen. Die Merkmale sind hierbei strukturelle Eigenschaften der einzelnen Knoten wie bspw. die Dichte eines Knotens oder die Anzahl an Nachbarn in einem Ego-Netzwerk. Die Signatur ergibt sich aus den einzelnen Aggregationen der Knoten wie bspw. der Median aus der Dichte der jeweiligen Knoten. So entsteht bspw. aus sieben Merkmalen und fünf Aggregationen ein Signaturvektor mit 35 verschiedenen Signaturen. So ermöglicht der Signaturvektor die Beschreibung als auch den Vergleich der einzelnen Graphen. Für den Vergleich wird die Canberra Distanz aus den beiden Signaturvektoren zweier zeitlich nebeneinander liegenden Graphen berechnet. [vgl. 2, S. 1]

Als Input für diesen Algorithmus wird eine Menge von  $k$ -anonymisierten Netzwerken mit beliebig unterschiedlichen Größen, die keine überlappenden Knoten oder Kanten besitzen sollten, herangezogen werden. Das Resultat sind Werte für die strukturelle Ähnlichkeit oder Abstands eines jeden Paares der gegebenen Netzwerke bzw. ein Merkmalsvektor für jedes Netzwerk. [vgl. 2, S. 1]

Netsimile durchläuft drei Schritte, die im Folgenden erläutert werden.

#### Extrahierung von Merkmalen

Für jeden Knoten  $i$  werden, basierend auf ihren Ego-Netzwerken, die folgenden Merkmale generiert:

$$\bar{d}_i = |N(i)|$$

Die Anzahl der Nachbarn (d.h. Grad) von Knoten  $i$ , wobei  $N(i)$  die Nachbarn von Knoten  $i$  beschreibt.

$$\bar{c}_i$$

Der Clustering-Koeffizient von Knoten  $i$ , der als die Anzahl von Dreiecken, die mit Knoten  $i$  verbunden sind, über die Anzahl von verbundenen Dreiecken, die auf Knoten  $i$  zentriert sind, definiert ist.

$$\bar{d}_{N(i)}$$

Die durchschnittliche Anzahl der Nachbarn von Knoten  $i$ , die zwei Schritte entfernt sind. Dieser wird berechnet als **todo: Paper Seite 2 unten Formel einfügen**

$$\bar{c}_{N(i)}$$

Der durchschnittliche Clustering-Koeffizient von  $N(i)$ , der als **todo: Paper Seite 2 unten Formel einfügen** berechnet wird.

$$|E_{ego(i)}|$$

Die Anzahl der Kanten im Ego-Netzwerk vom Knoten  $i$ , wobei  $ego(i)$  das Ego-Netzwerk von  $i$  zurückgibt.

$|E_{ego(i)}^o|$ Die Anzahl der von  $ego(i)$  ausgehenden Kanten. $|N(ego(i))|$ Die Anzahl von Nachbarn von  $ego(i)$ .

### Aggregierung von Merkmalen

Im nächsten Schritt wird für jeden Graphen  $G_j$  eine  $Knoten \times Merkmal$ -Matrix  $F_{G_j}$  zusammengefasst. Dieser besteht aus den Merkmalsvektoren aus Schritt 1. Da der Vergleich von  $k$ -ten  $F_{G_j}$  sehr aufwändig ist, wird für jede  $F_{G_j}$  ein Signaturvektor  $\vec{s}_{G_j}$  ausgegeben. Dieser aggregiert den Median, den Mittelwert, die Standardabweichung, die Schiefe, sowie die Kurtosis der Merkmale aus der Matrix.

### Vergleich der Signaturvektoren

Für die Ausreißererkennung werden die letzten drei Graphen anhand der Canberra-Distanz-Funktion, die als Ähnlichkeitsmaß dient, herangezogen. Steigt die Canberra Distanz zwischen zwei Graphen oberhalb des Thresholds so wird dies im Algorithmus festgehalten. Falls der darauf folgende Graph ebenfalls oberhalb des Thresholds liegt, so wird dieser als Ausreißer definiert. Dadurch wird die Anzahl der Ausreißer reduziert, damit nur diejenigen identifiziert werden, bei denen ein Trend hin zu einem abnormalen Verhalten erkennbar ist.

Der Algorithmus arbeitet dabei dynamisch, da die Signaturen der Graphen in einzelne Teil-Berechnungen aufgesplittet und zwischengespeichert werden können, ohne das eine Neuberechnung notwendig ist. Der Threshold wird aus dem Median und dem Mean berechnet, welche ebenfalls Zwischengespeichert werden können und nach Bedarf um weitere Graphen ergänzt werden können.

#### 4.2.2 Erweiterung des Algorithmus

Damit der Algorithmus auf Netzwerke angewendet werden kann, muss dieser vorab erweitert werden, da in Netzwerken ansonsten nur die Verbindung im Allgemeinen betrachtet wird, nicht aber die Häufigkeit an Verbindungen, die zwischen zwei Knoten stattgefunden hat. Damit würde ein großer Anteil des Datensatzes verloren gehen, da der Algorithmus keine Mehrfach-Verbindungen zwischen Knoten im Graphen darstellen kann.

Hierfür werden die Mehrfach-Verbindungen aufsummiert und als Kanten-Gewichtung zwischen zwei Knoten dem Graphen hinzugefügt.

```

1  for i in range(len(e_list)):
2      g.add_edge(e_list[i][0], e_list[i][1], weight=e_list[i][2])

```

**List. 4.1:** Gewichtung als neues Feature

Anschließend muss die Gewichtung aus diesem Graphen extrahiert werden. Dafür wird die Summe aller ausgehenden Kanten eines Knotens gebildet und als Feature hinzugefügt.

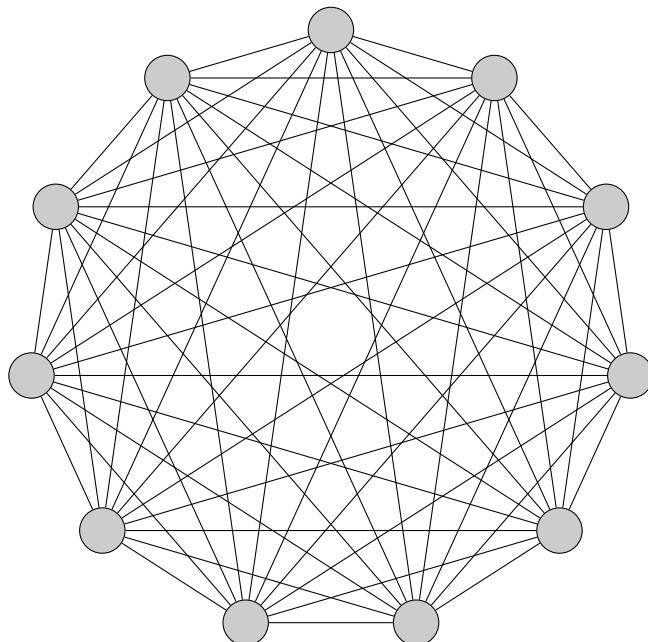
Für die Anwendung des Algorithmus auf Zeitreihen ist die Erweiterung um das Feature Gewichtung ebenfalls relevant, da sonst der Algorithmus auf einen vollständigen Graphen angewendet wird.

Das Problem hierbei ist, dass jeder Knoten eines Graphens die gleichen Features beinhalten würde. Dadurch würden die Aggregationen überflüssig werden und der Signaturvektor auf sieben Features schrumpfen. Die Bildung von Cluster-Features wäre demnach nur noch bedingt möglich und die Betrachtung an Nachbarn, unabhängig ob im Ego-Netzwerk oder im gesamten Netzwerk würde sich die Gesamtanzahl an Knoten annähern. Im Folgenden wird das Verhältnis der Features zum Durchschnitt dargestellt.

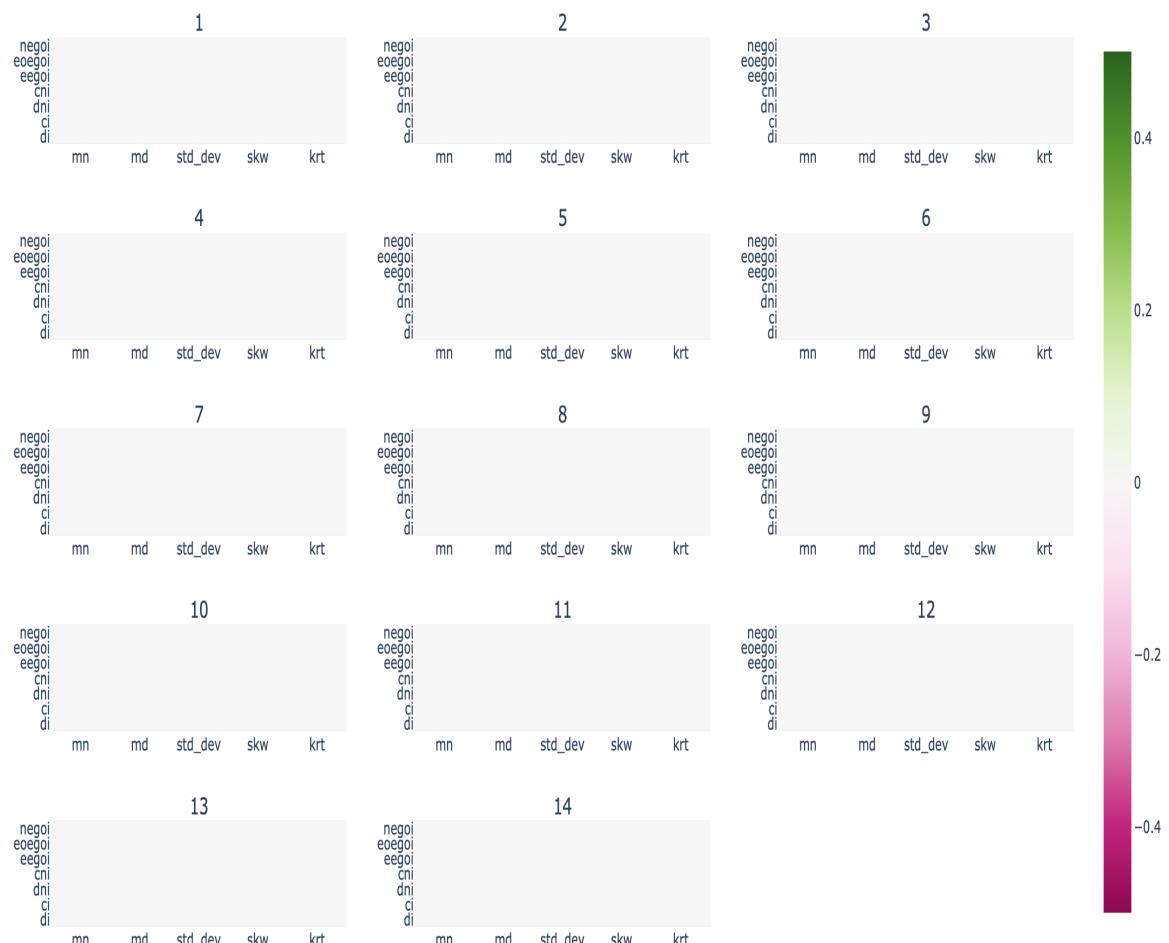
Man erkennt gut, dass die Features der einzelnen Graphen identisch sind, weshalb die Graphen denselben Threshold haben und somit den Wert 0 teilen.

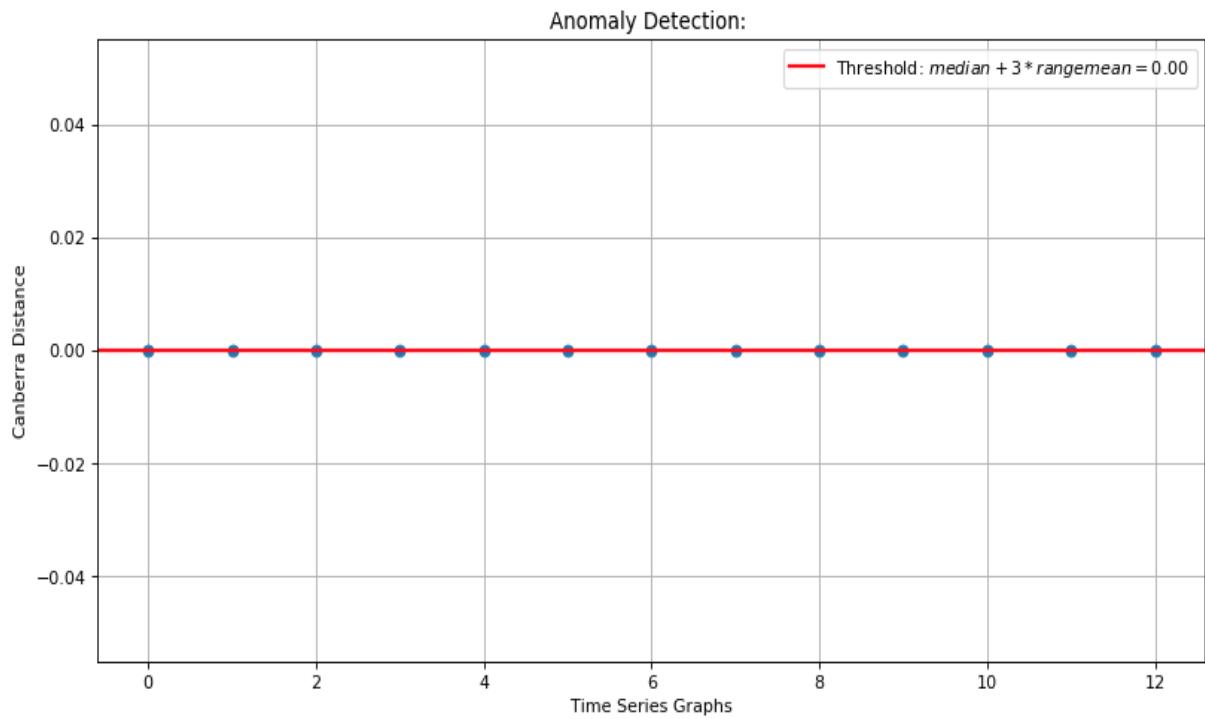
Dadurch ist die Ausreißererkennung von Zeitreihen in Graphen nicht möglich. Fügt man die Gewichtung als weiteres Feature hinzu, wird hier eine erste Betrachtung der Ausreißer möglich. Der Graph 10 wird hier wie erhofft als Ausreißer identifiziert.

**todo:** Struktur - Subsubsection

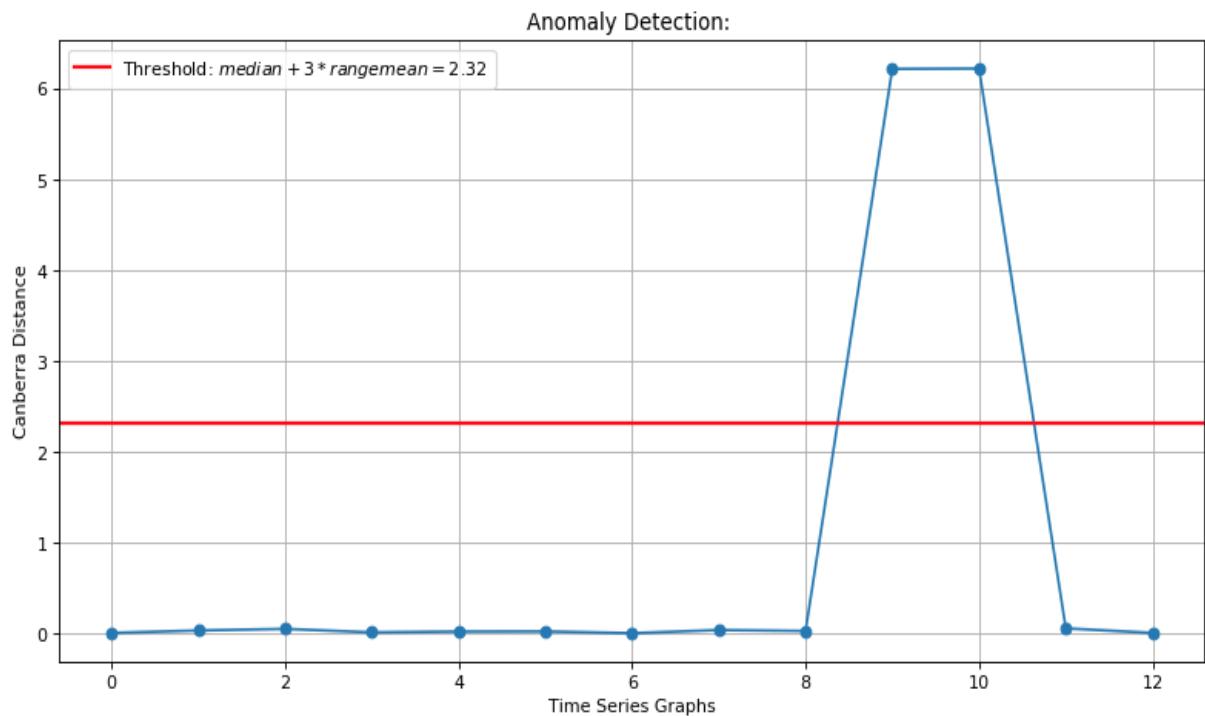


**Abb. 4.3:** Vollständiger Graph mit 11 Knoten

**Abb. 4.4:** Signaturvektoren der Zeitreihe mit vollständigen Graphen



**Abb. 4.5:** Ausreißer Score der vollständigen Graphen



**Abb. 4.6:** Ausreißer Score der vollständigen Graphen mit gewichteten Kanten

Netzwerk

### Enron

- Ausreißer werden erkannt
- todo: Dauer Berechnung

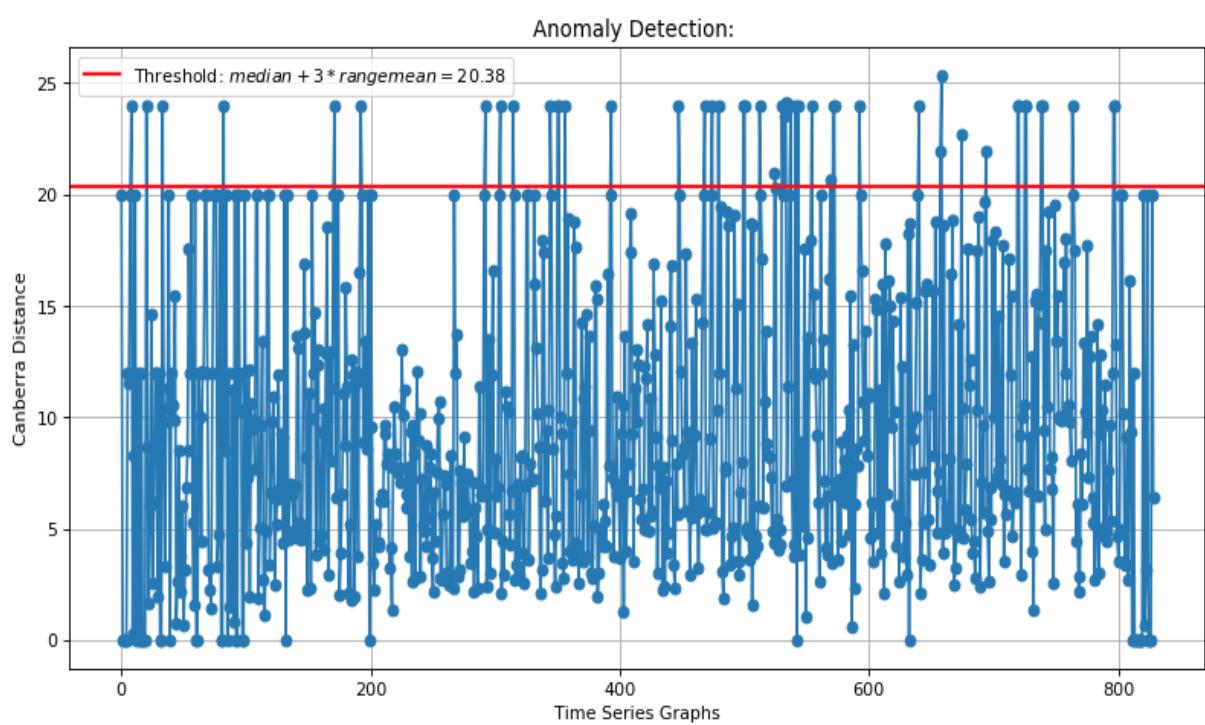
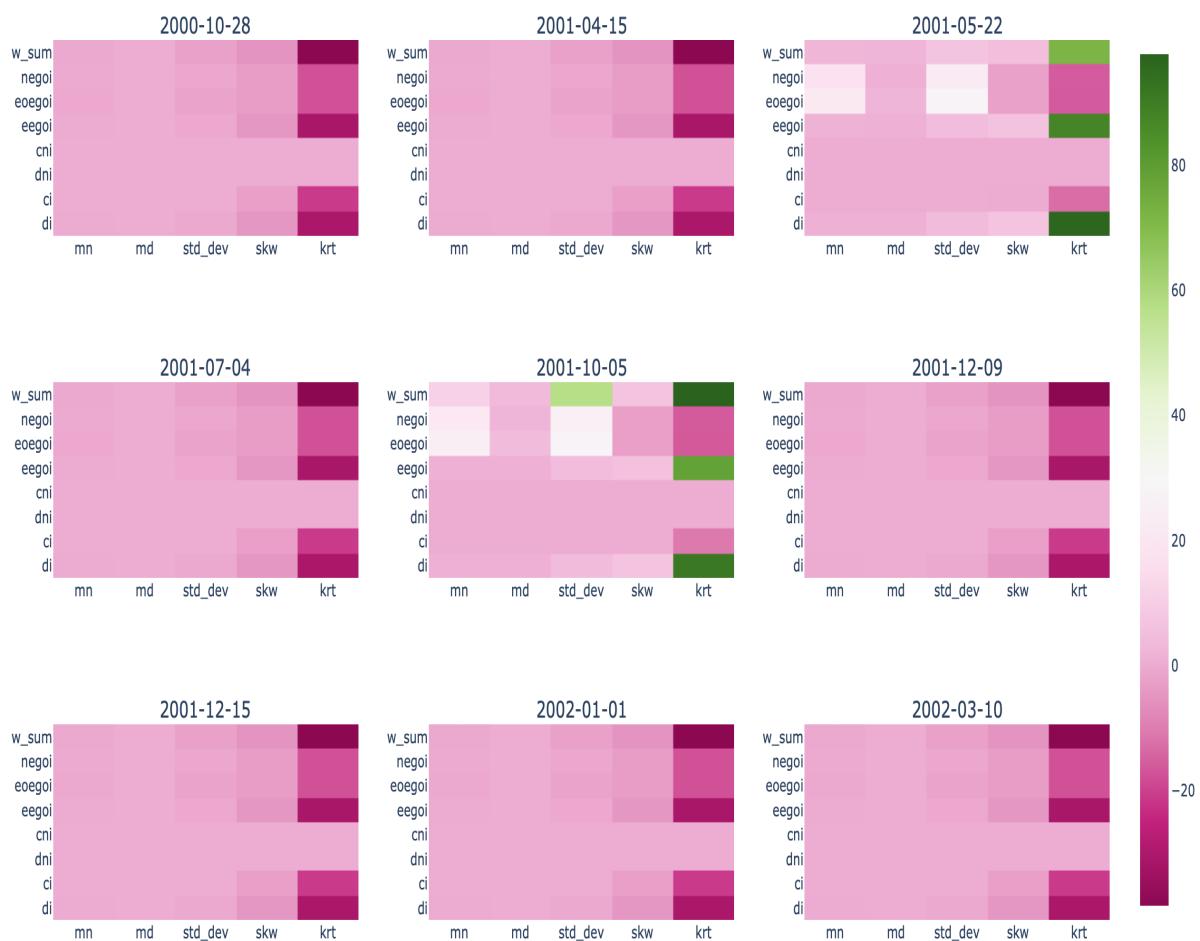


Abb. 4.7: Ausreißer Score Enron Datensatz

**Abb. 4.8:** Darstellung der Ausreißer in Heatmaps**Darpa**

- Ausreißer werden wahrgenommen
- Dauer Berechnung: 11150.692071 seconds

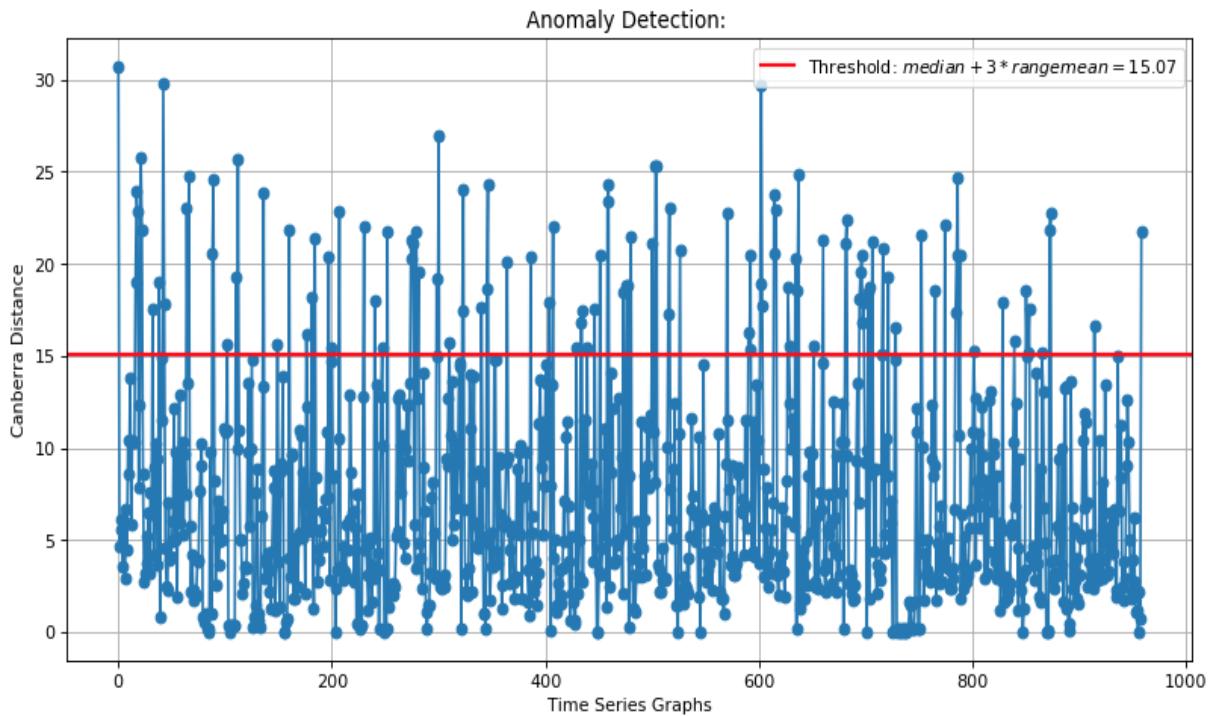


Abb. 4.9: Ausreißer Score DARPA

Zeitreihendaten

todo: Beschreibung als Fließtext, Verweise noch einfügen zu den Bildern

### Eindimensional

#### Mehrdimensional Probleme

- es werden Knoten generiert die gar nicht existieren im Datensatz

#### 4.2.3 Optimierte Implementierung des Algorithmus

Unter Verwendung der NetSimile Implementierung aus ??, benötigte die Ausführung des Algorithmus teilweise bis zu 30 Minuten. Aus diesem Grund wurde der Algorithmus von uns neu implementiert. Die Laufzeit konnte dabei auf wenige Sekunden reduziert werden, indem keine Graphen Bibliothek für die Implementierung verwendet wurde. Das heißt die Netzwerke der Zeitreihe werden nicht in ein Graphen Objekt umgewandelt, sondern als Adjazenzmatrix gespeichert. Dadurch können die Features deutlich effizienter berechnet werden. Des Weiteren wurden einige Features neu eingeführt und andere entfernt, sodass lediglich Features verwendet werden die für Fully Connected Graphen geeignet sind. So hat beispielsweise das Feature  $|E_{ego(i)}|$  keine Aussagekraft in einem Fully Connected Netzwerk, da jeder Knoten die gleiche Anzahl Kanten

Ausreißer Typ	Datei Name	1D	Beschreibung	Laufzeit
Einzelne Peaks	anomaly-art-daily-peaks	**	Zwei gemeinsame Peaks werden erkannt, Einzelne eher schlecht	61min
Zunahme an Rauschen	anomaly-art-daily-increase-noise	****	Ausreißer wird erkannt	51
Signal Drift	anomaly-art-daily-drift	**	Nur zwei von vier Ausreißer werden erkannt Die letzten zwei werden also normal definiert	57min
Kontinuierliche Zunahme der Amplitude	art-daily-amp-rise	****	Ausreißer werden erkannt	54min
Zyklus mit höherer Amplitude	art-daily-jumpsup	****	Ausreißer werden erkannt	50
Zyklus mit geringer Amplitude	art-daily-jumpsdown	****	Ausreißer werden erkannt	51min
Zyklus-Aussetzer	art-daily-flatmiddle	****	Ausreißer werden erkannt	62min
Signal-Aussetzer	art-daily-nojump	****	Ausreißer werden erkannt	65min
Frequenzänderung	anomaly-art-daily-sequence-change	****	Ausreißer werden erkannt	49min

**Tab. 4.1:** Ursprünglicher Netsimile Performance

in seinem Ego Netzwerk aufweist. Deshalb wurden folgende Features verwendet: **todo: Formeln ändern**

$|E_{ego(i)}^o|$   
Arithmetisches Mittel der Kantengewichte in  $ego(i)$ .

$|N(ego(i))|$   
Geometrisches Mittel der Kantengewichte in  $ego(i)$ .

$|E_{ego(i)}^o|$   
Geometrischs Mittel 10 Prozent der höchsten Kantengewichte in  $ego(i)$ .

$|E_{ego(i)}^o|$   
Geometrischer Mittel 20 Prozent der höchsten Kantengewichte in  $ego(i)$ .

Von diesen Features wurde dann auch den Median, den Mittelwert, die Standardabweichung, die Schiefe, sowie die Kurtosis berechnet. **todo: Bin mir nicht sicher zu welchen Elementen die Canbarra Distanz berechnet wird.** Des Weiteren wurde ein neuer Parameter eingeführt. Über diesen kann gesteuert werden zu wie vielen vorgänger Abschnitten die Distanz berechnet werden

soll. Dadurch kann gesteuert werden wie schnell ein Algorithmus vergisst. Eine Auflistung der Parameter des Algorithmus ist in Tab. 4.2 zu sehen.

### Ausreißer-Erkennung in Zeitreihen

Um zu untersuchen, wie gut der Algorithmus funktioniert, wurde er auf Zeitreihen getestet. Als Testdaten wurden, ein und zweidimensionale Zeitreihen der Numenta Gruppe verwendet. Diese Zeitreihen enthalten verschiedene Ausreißer Typen, auf deren Erkennung der Algorithmus getestet wurde. Die Qualität der Ausreißererkennung wurde mithilfe eines Punktesystem bewertet. Dabei bedeuteten 0 Punkte, Ausreißer nicht erkannt und 4 Punkte bedeuteten Ausreißer sehr gut erkannt. Die Parameter, welche für die Tests gewählt werden mussten, werden in Tab. 4.2 beschrieben.

Tab. 4.3 zeigt die Ergebnisse der Tests. Es ist zu erkennen, dass die Qualität der Ausreißererkennung im eindimensionalen Fall sehr gut ist. Lediglich einzelne Peaks können durch den Algorithmus nicht als Ausreißer identifiziert werden. Außerdem wird bei Signal Drifts und der kontinuierlichen Zunahme der Amplitude lediglich der Anfang des Ausreißers detektiert. Aus diesem Grund wurde eine Bewertung mit drei Sternen vergeben. Bei der Betrachtung der Graphiken in Kap. A.2 und Kap. A.3 ist zu erkennen, dass das sechste oder siebte Intervall der Zeitreihe häufig als Ausreißer markiert wird. Der Grund hierfür ist, dass bei einer Fenstergröße von fünf für die ersten fünf Abschnitte kein Ausreißer Score berechnet wird. Dadurch ist die Standardabweichung zu Beginn sehr niedrig wodurch Abschnitte schnell als Ausreißer gekennzeichnet werden. Dieser Umstand wurde bei der Bewertung in Tab. 4.3 nicht berücksichtigt. Im zweidimensionalen Fall ist die Qualität der Ausreißererkennung etwas durchwachsener. Auffallend ist, dass Zyklen mit höherer und niedriger Amplitude nicht als Ausreißer erkannt werden. Insbesondere ist dies auffällig, da diese Ausreißer Typen üblicherweise zuverlässig erkannt werden (vgl. ??). Außerdem ist der Algorithmus im zweidimensionalen Fall nicht mehr dazu in der Lage Signal Drifts

Parameter	Beschreibung
Periodizität	Wie in Kap. 3.1 todo: Referenz sollte glaube ich autoref -> sec:trsnsNeti sein erläutert muss die Zeitreihe in kleinere Intervalle aufgegliedert werden. Über diesen Parameter wird die Größe der Intervalle gesteuert. Für die Tests wurde der Parameter auf 288 gesetzt, da es sich hierbei um die Saisonalität der Zeitreihen handelt.
Fenstergröße	Wie in Kap. 4.2.3 erklärt, bestimmt dieser Parameter die Anzahl der vorangegangenen Abschnitte zu welchen die Canberra Distanz berechnet wird. Dieser Parameter wurde für die Tests auf 5 gesetzt.
Abweichung	Legt fest ab wann es sich bei einem Abschnitt um einen Ausreißer handelt. Der Parameter wurde für die Tests auf 3 gesetzt. Bedeutet wenn der Ausreißer Score um das dreifache der Standardabweichung vom Durchschnitt abweicht, wird der Abschnitt als Ausreißer gekennzeichnet.

Tab. 4.2: Parameter Netsimile Zeitreihen

Ausreißer Typ	Datei Name	1D	2D
Einzelne Peaks	anomaly-art-daily-peaks	-	-
Zunahme an Rauschen	anomaly-art-daily-increase-noise	****	***
Signal Drift	anomaly-art-daily-drift	***	-
Kontinuierliche Zunahme der Amplitude	art-daily-amp-rise	***	***
Zyklus mit höherer Amplitude	art-daily-jumpsup	****	*
Zyklus mit geringerer Amplitude	art-daily-jumpsdown	****	-
Zyklus-Aussetzer	art-daily-flatmiddle	****	***
Signal-Aussetzer	art-daily-nojump	****	***
Frequenzänderung	anomaly-art-daily-sequence-change	****	***

**Tab. 4.3:** Netsimile Time Series Perfomance

zu erkennen. Andere Ausreißer Typen können durch den Algorithmus weiterhin erkannt werden, jedoch oftmals nicht mit der selben Qualität.

## 4.3 MIDAS

todo: In diesem Kapitel werden grundlegende Themen behandelt, die im Rahmen des Forschungsprojekts zum Verständnis der Ausreißer-Erkennung in Graphen gedient haben.

Erst erklären wie der MIDAS funktioniert. Und zum Laufen gebracht mit Graphen über die Zeit ENRON & DARPA. Im Anschluss auf Zeitreihendaten angewendet.

### 4.3.1 Grundlagen

todo: Einführung in den Algorithmus, NodeHash- sowie EdgeHash-Funktionen beschreiben

MIDAS, Eng. *Microcluster-Based Detector of Anomalies in Edge Streams*, steht für einen Algorithmus, der plötzlich auftretende Ausbrüche von Aktivitäten in einem Netzwerk bzw. Graphen erkennt. Dieses vermehrte Auftreten von Aktivitäten zeigt sich durch viele sich wiederholende Knoten- und Kantenpaare in einem sich zeitlich entwickelnden Graphen, die Mikrocluster bezeichnet werden. Mikrocluster bestehen demnach aus einem vermehrten Vorkommen eines einzigen Quell- und Zielpaars bzw. einer Kante  $(u,v)$  todo: Folgender Absatz kann vor der Beschreibung des Algorithmus eingefügt werden, wie im Paper auch Dies geschieht in Echtzeit, wobei jede Kante in konstanter Zeit und Speicher verarbeitet wird. In der Theorie garantiert er eine False-positive-Wahrscheinlichkeit und ist durch einen 162 bis 644 mal schnelleren Ansatz, sowie einer 42% bis 48% höhere Genauigkeit, im Hinblick auf die AUC, sehr effektiv. [vgl. 3, S. 1]

Anwendungsfälle für MIDAS sind die Erkennung von Anomalien in Computer-Netzwerken, wie SPAM oder DoS-Angriffe oder Anomalien in Kreditkartentransaktionen.

#### Count-Min-Sketch

Damit die relevanten Informationen für den Algorithmus mit einem konstanten Speicher verarbeitet werden, wird Count-Min-Sketch genutzt, dass eine Streaming-Datenstruktur mithilfe der Nutzung von Hash-Funktionen entspricht. Count-Min-Sketch zählt somit die Frequenz einer Aktivität bei Streaming-Daten. Diese Datenstruktur hat ebenfalls den Vorteil, dass man zu Beginn keine Kenntnis über die Anzahl an Quell- und Zielpaaren haben muss. [6]

MIDAS verwendet zwei Arten von CMS. Die erste Variante  $s_{uv}$  wird als die Anzahl an Kanten von  $u$  zu  $v$  bis zum aktuellen Zeitpunkt  $t$  definiert. Durch die CMS-Datenstruktur werden alle Zählungen von  $s_{uv}$  approximiert, sodass jederzeit eine annähernde Abfrage  $\hat{s}_{uv}$  erhalten werden kann. Die zweite Variante  $a_{uv}$  wird als die Anzahl an Kanten von  $u$  zu  $v$  im aktuellen Zeitpunkt  $t$  definiert. Dieser CMS ist identisch zu  $s_{uv}$ , wobei bei jedem Übergang zum nächsten Zeitpunkt die Datenstruktur zurückgesetzt wird. Dadurch resultiert aus dem CMS für den aktuellen Zeitpunkt die annähernde Abfrage  $\hat{a}_{uv}$ . [vgl. 3, S. 3]

### Erkennung von Mikrocluster

Mithilfe der Näherungswerte  $\hat{s}_{uv}$  und  $\hat{a}_{uv}$  ist das Detektieren von Mikroclustern möglich. Hierzu wird der mittlere Pegel todo: andere übersetzung für mean level? (d.h. die durchschnittliche Rate mit der Kanten erscheinen) betrachtet. Es wird hierbei angenommen, dass dieser für den aktuellen Zeitpunkt (z.B.  $t = 10$ ) äquivalent ist zu dem vor dem aktuellen Zeitpunkt ( $t < 10$ ). Dadurch wird die Annahmen vermieden, dass die Daten auf einer bestimmten zugrundeliegenden Verteilung basieren oder Stationarität über die Zeit aufweisen.

Durch die genannte Annahme lassen sich vergangene Kanten in zwei Klassen einteilen. Eine für den aktuellen Zeitpunkt  $t = 10$  und eine für alle vergangenen Zeitpunkte  $t < 10$ . Hierbei beträgt die Anzahl der Ereignisse zum Zeitpunkt  $t = 10$   $a_{uv}$  und die Anzahl der Kanten in vergangenen Zeitpunkten  $t < 10$  ist  $s_{uv} - a_{uv}$ .

Die Auswertung der Daten kann mithilfe des chi-squared goodness-of-fit test erfolgen. Hierbei wird die Summe der Klassen  $t = 10$  und  $t < 10$  für  $\frac{\text{beobachtet} - \text{erwartet}}{\text{erwartet}}^2$  bestimmt. Bei einer Gesamtanzahl von  $s_{uv}$  Kanten ergibt sich, auf Basis eines mittleren Pegels todo: wie oben andere bezeichnung?, für  $t = 10$  eine erwartete Anzahl von  $\frac{s_{uv}}{t}$  Kanten todo: oder ereignisse?. Analog hierzu ergibt sich für  $t < 10$  eine erwartete Anzahl an  $\frac{t-1}{t}s_{uv}$  vergangenen Kanten. Daraus ergibt sich für die chi-squared Statistik [vgl. 3, S. 3]:

$$\begin{aligned}\chi^2 &= \frac{\left(\text{beobachtet}_{(t=10)} - \text{erwartet}_{(t=10)}\right)^2}{\text{erwartet}_{(t=10)}} \\ &+ \frac{\left(\text{beobachtet}_{(t<10)} - \text{erwartet}_{(t<10)}\right)^2}{\text{erwartet}_{(t<10)}} \\ &= \frac{\left(a_{uv} - \frac{s_{uv}}{t}\right)^2}{\frac{s_{uv}}{t}} + \frac{\left((s_{uv} - a_{uv}) - \frac{t-1}{t}s_{uv}\right)^2}{\frac{t-1}{t}s_{uv}} \\ &= \frac{\left(a_{uv} - \frac{s_{uv}}{t}\right)^2}{\frac{s_{uv}}{t}} + \frac{\left(a_{uv} - \frac{s_{uv}}{t}\right)^2}{\frac{t-1}{t}s_{uv}} \\ &= \left(a_{uv} - \frac{s_{uv}}{t}\right)^2 \frac{t^2}{s_{uv}(t-1)}\end{aligned}\tag{4.1}$$

Die Größen  $a_{uv}$  und  $s_{uv}$  können, mithilfe der CMS-Datenstruktur, approximiert werden. Daraus ergibt sich, unter Verwendung der approximierten Größen  $\hat{a}_{uv}$  und  $\hat{s}_{uv}$ , der folgende Anomaly Score [vgl. 3, S. 4]:

$$score((u,v,t)) = \left(\hat{a}_{uv} - \frac{\hat{s}_{uv}}{t}\right)^2 \frac{t^2}{\hat{s}_{uv}(t-1)}\tag{4.2}$$

Mithilfe des in Gl. 4.2 angegeben Anomaly Score lässt sich eine neue Kante  $(u,v)$  zum Zeitpunkt

$t$  bewerten. Dieser wird in einem binären Entscheidungsverfahren verwendet, um zu bestimmen, ob es sich bei einer neuen Kante um Anomalie handelt oder nicht. Die Wahrscheinlichkeit von false positive Ergebnissen soll hierbei nicht einen benutzerdefinierten Schwellenwert  $\epsilon$  übersteigen. CMS-Datenstrukturen mit einer angemessenen Größe besitzen die Eigenschaft, dass die Approximationen  $\hat{a}_{uv}$ , für beliebige  $\epsilon$  und  $\nu$ , folgende Vorschrift mit einer Wahrscheinlichkeit von mindestens  $1 - \frac{\epsilon}{2}$  erfüllen:

$$\hat{a}_{uv} \leq a_{uv} + \nu \cdot N_t \quad (4.3)$$

$N_t$  beschreibt hierbei die Anzahl an Kanten zum Zeitpunkt  $t$ . Eine weitere Eigenschaft der CMS-Datenstrukturen ist, dass diese die tatsächlichen Anzahl an Kanten nur überbewerten können:

$$s_{uv} \leq \hat{s}_{uv} \quad (4.4)$$

Der in Gl. 4.2 gegebene Score kann wie folgt angepasst werden:

$$\tilde{a}_{uv} = \hat{a}_{uv} - \nu N_t \quad (4.5)$$

Daraus lässt sich die in Gl. 4.1 gegebene Statistik anpassen:

$$\tilde{\chi}^2 = \left( \tilde{a}_{uv} - \frac{s_{uv}}{t} \right)^2 \frac{t^2}{s_{uv}(t-1)} \quad (4.6)$$

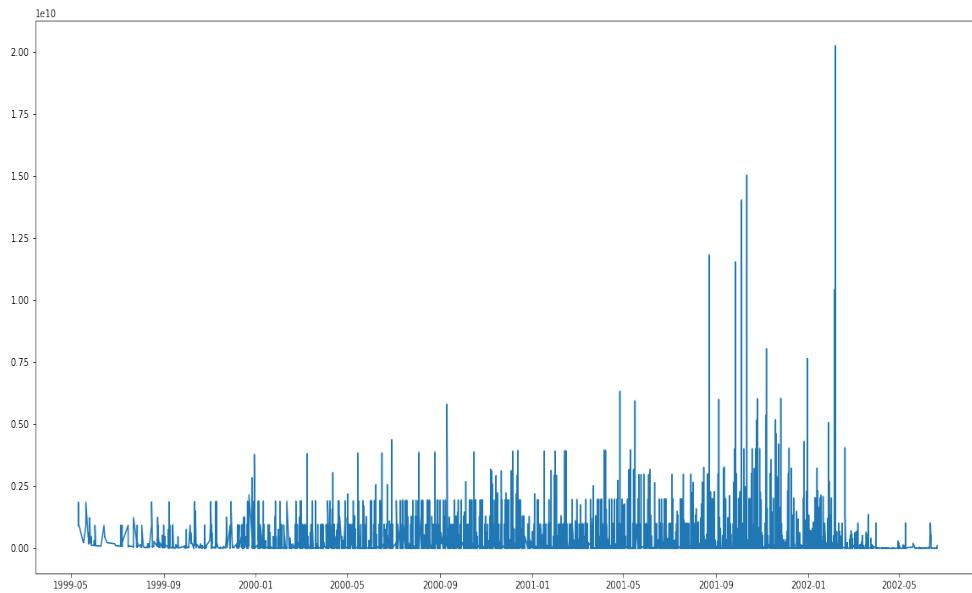
Bei Verwendung der Teststatistik in Gl. 4.6 und eines Schwellenwertes von  $\chi^2_{1-\frac{\epsilon}{2}}(1)$  ergibt sich eine Wahrscheinlichkeit für ein false positive Ergebnis von höchstens  $\epsilon$ :

$$P \left( \tilde{\chi}^2 > \chi^2_{1-\frac{\epsilon}{2}}(1) \right) < \epsilon \quad (4.7)$$

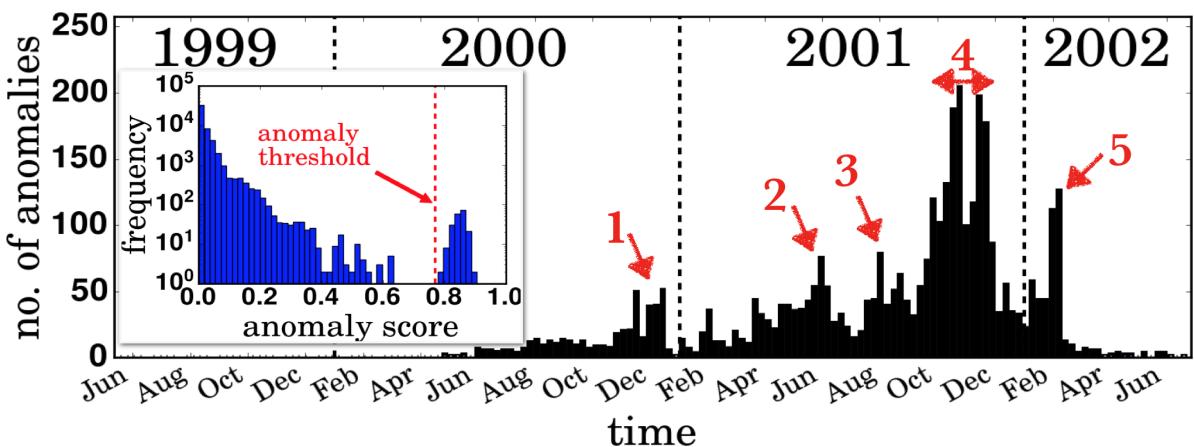
Der Term  $\chi^2_{1-\frac{\epsilon}{2}}(1)$  beschreibt hierbei das  $1 - \frac{\epsilon}{2}$ -Quantil.

## 4.4 Ausreißer-Erkennung in Graphen

todo: ausformulieren



**Abb. 4.10:** Der Ausreißer-Score über die Zeit beim ENRON-Datensatz



**Abb. 4.11:** Die Ausreißer des SEDANSPOT-Algorithmus

Die Herausforderung geeignete *labels* für die Datensätze zu finden wird in zwei Schritten eingedämmt.

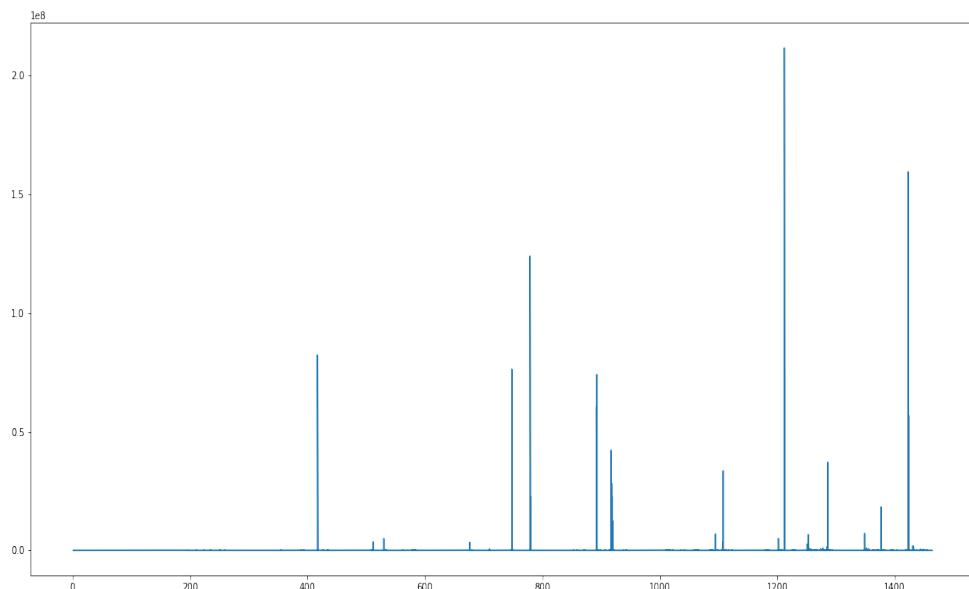
Zum einen werden Erkenntnisse aus dem Schaubild des SEDANSPOT-Algorithmus gewonnen  
**todo: Quelle eingeben.** Hierbei kann man sehen, dass beide Algorithmen einen ähnlichen Verlauf vorweisen. Im nächsten Schritt wird die selbe Vorgehensweise wie aus dem SEDANSPOT-Paper

gewählt und die ENRON Timeline *todo: Quelle einfügen wie bei Datensatz-Kapitel* zur Erhebung von möglichen Auswirkungen für die Ausreißer hinzugezogen.

Die Tab. 4.4 bietet eine Übersicht der historischen Ereignisse, die die Ausreißer des MIDAS-Algorithmus erklären. Im Vergleich zum SEDANSPOT-Algorithmus werden mehr Ausreißer erkannt.

1.	Aktie erreicht Allzeithoch. Federal Energy Regulatory Commission ordnet Untersuchung an.
2.	<ul style="list-style-type: none"> <li>• Vierteljährliche Telefonkonferenz zur Finanzsituation und erste Symptome eines Problems.</li> <li>• „Geheimes“ Treffen – Schwarzenegger, Lay, Milken. Angebot zur Rettung der Deregulierung.</li> </ul>
3.	<ul style="list-style-type: none"> <li>• Skilling (CEO) kündigt. Mitarbeiterin warnt Lay (Gründer) vor Pleite. Skilling verkauft seine Aktien.</li> <li>• Enron veröffentlicht 618 Mio. \$ Verlust. Interessenskonflikt wird untersucht und Akten vernichtet.</li> </ul>
4.	<ul style="list-style-type: none"> <li>• Beginn der Strafverfolgung. Lay's Rücktritt</li> <li>• Internen Ermittlung verteilt die Schuld auf Führungskräfte und den Vorstand</li> </ul>

**Tab. 4.4:** Übersicht über historische Ereignisse, die den Ausreißern zuzuordnen sind



**Abb. 4.12:** Der Ausreißer-Score über die Zeit beim DARPA-Datensatz

Bei der Anwendung des MIDAS auf dem DARPA-Datensatz sieht man sehr schön einzelne Aus-

reißer, die entdeckt wurden. Für diesen Datensatz gibt es, speziell für MIDAS entwickelt, einen *ground truth*, der die *labels* für diesen Datensatz zur Verfügung stellt.

Bei der Berechnung der "Area under the Curve " für die ermittelten Ausreißer-Scores wird ein Wert von 0.9172724836793507 berechnet. Das bedeutet, dass der MIDAS-Algorithmus mit einer Wahrscheinlichkeit von ca. 91,73% die Kanten des Datensatzes richtig klassifiziert.

Somit kann festgehalten werden, dass MIDAS ein sehr guter Algorithmus ist bei der Erkennung von Ausreißern in Graphen und eine sehr hohe Genauigkeit erreicht.

**todo:** Schwierigkeit geeignete Datensätze zu finden, dazu gibt es ein Paper. Wenn man die Anomalyscores als gewichte nimmt, kommen Graphen in Networkx raus in denen man die anomalous nodes identifizieren kann dabei sollten es Edges sein

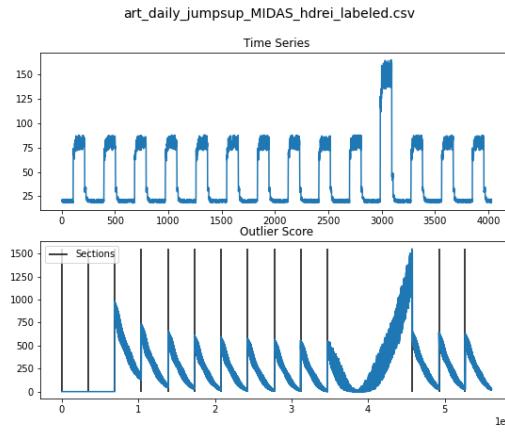
## 4.5 Ausreißer-Erkennung in Zeitreihen

**todo:** Tabelle wie für Netsimile einfügen bzgl. den verschiedenen Numenta-Datensätzen. Bisher nicht dringlich gewesen, da MIDAS schlecht ist und wir das für den abstract nicht benötigen

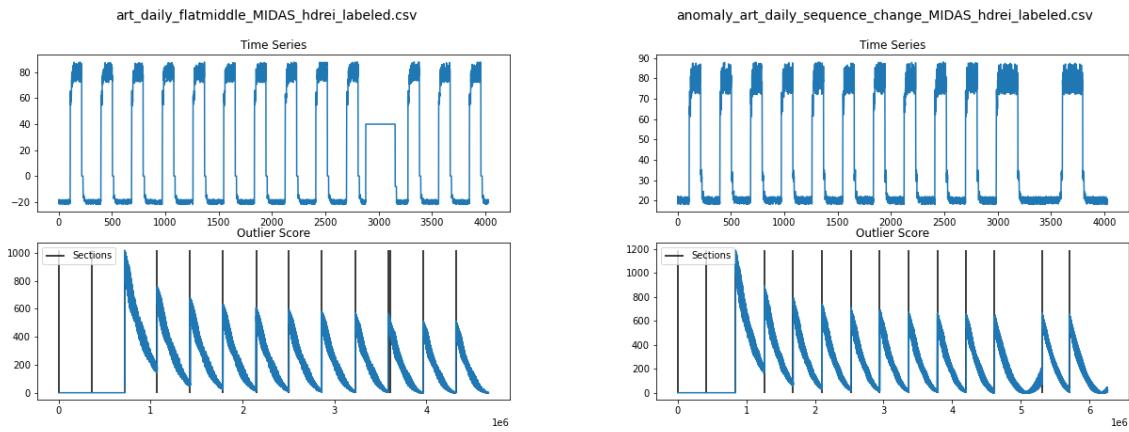
Um den MIDAS Algorithmus auf Zeitreihen anwenden zu können muss die Zeitreihe, wie in ?? beschrieben, zunächst in verschiedene Netzwerke umgewandelt werden. Bei den Tests konnte festgestellt werden, dass der MIDAS Algorithmus nicht dazu in der Lage ist Ausreißer in Zeitreihen zu erkennen. Die vollständigen Ergebnisse der Tests können in Kap. B eingesehen werden. Hierbei ist jedoch der Verlauf des Ausreißer Scores schwierig zu interpretieren. Es ist zu erkennen, dass der Ausreißer-Score zu Beginn eines jeden Abschnitts sehr hoch ist, am Ende des Abschnitts ist der Ausreißer Score hingegen relativ niedrig. Grund hierfür ist, dass die Anzahl an Kanten zu Beginn eines Abschnitts im Verhältnis zu der Anzahl an Kanten aus den vorangegangenen Abschnitten deutlich niedriger ist. Im weiteren Verlauf werden weitere Kanten innerhalb des Abschnitts hinzugefügt. Dadurch gleicht sich die Anzahl an Kanten innerhalb der Abschnitte an und der Ausreißer Score sinkt.

Der MIDAS Algorithmus ist lediglich bei einer Zeitreihe dazu in der Lage den Ausreißer zu identifizieren. Hierbei handelt es sich um die Zeitreihe mit erhöhter Amplitude (vgl. Abb. 4.13). Durch den Ausschlag nach oben in der Zeitreihe entsteht ein Netzwerk, mit sehr hohen Gewichten. Die hohen Gewichte führen zu einer erhöhten Anzahl an Kanten, was schlussendlich zu einem Ausschlag des Ausreißer Scores führt. Die erhöhte Anzahl an Kanten führt ebenfalls dazu, dass der Abschnitt mit dem Ausreißer in der Abbildung deutlich breiter ist als die anderen. Bei anderen Ausreißer Typen sind die Differenzen zwischen den verschiedenen Elementen der Zeitreihe nicht so groß. Dadurch ergeben sich keinerlei hohe Kantengewichte und der Ausreißer kann nicht erkannt werden.

Teilweise führen die Ausreißer auch zu besonders wenigen Kanten (vgl. Abb. 4.14). Bei diesem Ausreißer Typ sind alle Werte auf der selben Ebene. Dadurch gehen die Kantengewichte gegen Null. Dies führt zu einem sehr kurzen Abschnitt in der Abbildung (Der Abschnitt wurde mit einem Pfeil markiert). **todo:** Noch Pfeil in Graphik einfügen Des weiteren ergibt sich durch die Ausreißer eine leicht veränderte Anzahl an Kanten in dem Abschnitt mit dem Ausreißer (vgl. Abb. 4.14). Die Abweichungen sind jedoch so gering, dass es nicht zu einem starken Anstieg des Ausreißer Scores führt.



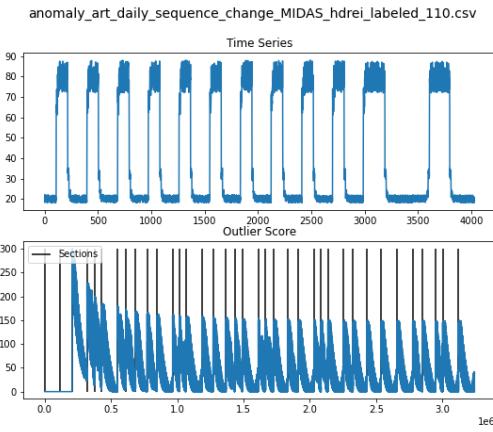
**Abb. 4.13:** MIDAS Algorithmus angewandt auf Zeitreihe mit einer erhöten Amplitude.



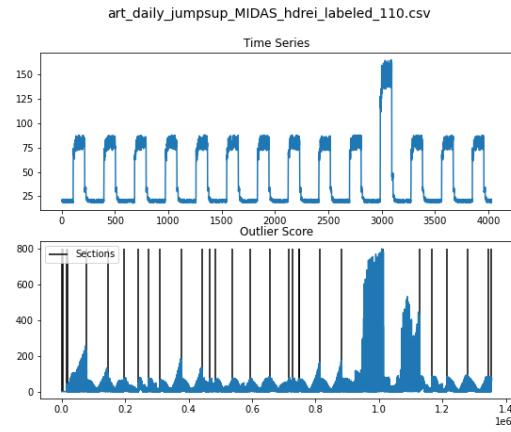
**Abb. 4.14:** Ausreißer Erkennung in Zeitreihen MIDAS Algorithmus

Es wurden außerdem Tests durchgeführt um zu untersuchen, wie sich der Algorithmus bei veränderter Fenstergröße verhält (vgl. Abb. 4.15). Bei den Untersuchungen in Abb. 4.13 und Abb. 4.14 wurde eine Fenstergröße von 288 genutzt, was der Saisonalität der Zeitreihe entspricht. Für dieses Experiment wurde eine Fenstergröße von 110 verwendet. Es konnte festgestellt werden, dass diese Veränderung keinen zusätzlichen Nutzen erbringt. Allerdings ist der Ausschlag nach oben im Ausreißer Score für die Zeitreihe mit erhöhter Amplitude noch deutlicher zu erkennen. Die anderen Ausreißer Typen werden weiterhin nicht erkannt.

In einem nächsten Schritt wurde untersucht inwiefern der MIDAS-R Algorithmus zu einer Verbesserung bei der Ausreißer Erkennung beitragen kann (vgl. Abb. 4.16). Der MIDAS-R Algorithmus berücksichtigt bei der Berechnung des Ausreißer Scores für den aktuellen Abschnitt auch die Daten aus der jüngsten Vergangenheit(vorangegangene Abschnitte). Aus diesem Grund erhofften wir uns durch den Einsatz des MIDAS-R Algorithmus, dass die Ausschläge zu Beginn eines jeden Abschnitts ausbleiben, sodass Ausreißer deutlicher hervortreten. Es konnte festgestellt werden,



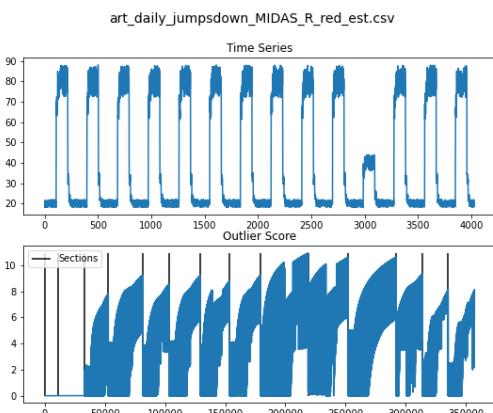
(a) Zeitreihe mit einer Frequenzänderung



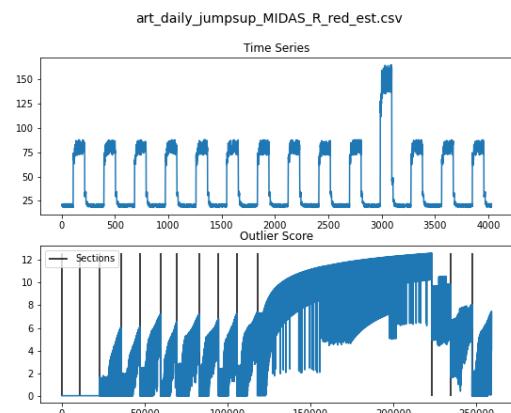
(b) Zeitreihe mit erhöhter Amplitude

**Abb. 4.15:** Ausreißer Erkennung Zeitreihen MIDAS Algorithmus Fenstergröße 110

dass der Ausschlag des Ausreißer Scores zu Beginn der Abschnitte deutlich kleiner ist. Jedoch steigt der Ausreißer Score zum Ende eines jeden Abschnitts wieder an. Es konnte somit keine Signifikante Verbesserung bei der Erkennung von Ausreißern erreicht werden. Insbesondere da der MIDAS-R Algorithmus ebenfalls nur den Ausreißer in der Zeitreihe mit erhöhter Amplitude anzeigt. Somit konnte festgestellt werden, dass auch die durch den MIDAS-R Algorithmus eingeführten Features zu keiner Verbesserung der Ergebnisse geführt haben. **todo: Vielleicht könnte eine Verbesserung erreicht werden wenn andere Features eingeführt werden würden.**



(a) Zeitreihe mit geringerer Amplitude



(b) Zeitreihe mit erhöhter Amplitude

**Abb. 4.16:** Ausreißer Erkennung Zeitreihen MIDAS-R

# 5 Fazit und Ausblick

## 5.1 Fazit

Das dritte Teilziel ist es die verschiedenen graphen-basierten Algorithmen, die wir im Rahmen des fortgeführten Forschungsprojekt analysiert und evaluiert haben miteinander zu vergleichen. (vgl. Kap. 1.1) Durch den Vergleich soll ermittelt werden, wie erfolgreich ein Algorithmus bei der Erkennung von Ausreißern in Daten ist.

	Statisch	Dynamisch	Qualität Ausreißer- Erkennung Netzwerke	Qualität Ausreißer- Erkennung Zeitreihen	Performanz
IsoMap-based	+	-	-	o	+
Perculation-based	+	-	-	+	+
Netsimile	-	+	+	++	+
MIDAS	-	+	++	-	o

**Tab. 5.1:** Vergleich der Algorithmen

Aus der Tabelle Tab. 5.1 kann man die Kriterien entnehmen, die zum Vergleich der Algorithmen herangezogen wurden. So werden alle Algorithmen zunächst einmal in statisch und dynamisch entsprechend der Taxonomie des Forschungsprojekts unterteilt. Im nächsten Schritt werden die Ergebnisse aller Algorithmen hinsichtlich ihrer Fähigkeit Ausreißer in Graphen, sowie in Zeitreihen qualitativ zu erkennen gegenübergestellt. Zuletzt liegt der Fokus auf ihrer Performance im Vergleich zu den anderen Algorithmen. Nachfolgend werden die Ergebnisse ausgeführt.

**todo: die Vergleiche autoref einfügen.** Der IsoMap-based und der Perculation-based Algorithmus sind statische Algorithmen, die jeweils nur auf einem Graphen angewendet werden können. Aus diesem Grund eignen sich diese nicht für die Ausreißer-Erkennung in Netzwerken, da hier mehrere Graphen übergeben werden. Beide können jedoch erfolgreich auf Zeitreihen angewendet werden, wobei beim IsoMap-based Algorithmus die Ausreißer nur teilweise erkennbar sind, da sich die Ausreißer nur geringfügig von den anderen Werten unterscheiden. Der Perculation-based Algorithmus hingegen zeigt eindeutige Ausreißer, weshalb dieser Algorithmus geeignet ist für eine qualitative Ausreißer-Erkennung. Bei den Ausreißer Typen "Signal-Aussetzer" und "Frequenzänderung" können beide Algorithmen keine Ausreißer identifizieren. Die Performance beider Algorithmen ist gut, da sie die Berechnungen innerhalb weniger Sekunden durchführen.

Der Netsimile- und der MIDAS-Algorithmus können beide auf Netzwerkdatensätzen angewendet werden, da sie dynamisch sind. Der Unterschied hierbei liegt bei dem Ausreißer-Score. Beim Netsimile sind die erkannten Ausreißer nahezu identisch, wodurch eine Klassifizierung unzureichend ist. Beim MIDAS hingegen sind die Ausschläge weitaus größer, wodurch eine Klassifizierung erzielt wird. Bei der Anwendung auf Zeitreihen liefert der Netsimile sehr gute Ergebnisse auf den Ausreißer-Typen die wir verwendet haben (vgl. Kap. 4.2.3). Da sich bei der Transformation von Zeitreihen zu Graphen die Gewichtung nur geringfügig unterscheidet und der MIDAS-Algorithmus Ausreißer nur bei einer hohen Kantengewichtung erkennt, fallen die Ergebnisse hier schlechter aus (vgl. Kap. 4.5). Dementsprechend ist MIDAS für die Erkennung von Ausreißern in Zeitreihen eher ungeeignet. Bei der Performanz hat der Netsimile-Algorithmus ursprünglich bis zu einer Stunde benötigt, da dieser rechenintensive Bibliotheken verwendete. Durch die Verwendung anderer Bibliotheken wurde eine Optimierung erreicht. Die Visualisierung des Graphens ist hierdurch zwar nicht mehr möglich, jedoch wird die Rechenzeit auf wenige Sekunden reduziert. Der MIDAS benötigt hingegen mehrere Minuten, wodurch der Netsimile nach der Optimierung performanter geworden ist. (VGL: PERFORMANZ-TABELLE dann im Anhang)

Der Netsimile-Algorithmus ist demnach ein Algorithmus, der, nach Optimierung, den Anforderungen des Forschungsprojekts gerecht wird. Dieser Algorithmus ist dynamisch, multidimensional, performant und die Erkennung von Ausreißern in Zeitreihen ist sehr gut. Der Schwerpunkt hierbei liegt bei der Wahl der richtigen Features. Strukturelle Merkmale sind eher ungeeignet bei vollständig verknüpften Graphen und sollten ersetzt werden durch Features, wie bspw. die Gewichtung der Kanten.

**todo:** Tabelle in den Anhang

	Netsimile	MIDAS
AmpRise	54 min 32 sec	05 min 26 sec
Drift	57 min 29 sec	05 min 22 sec
Flatmiddle	62 min 50 sec	06 min 01 sec
Increase Noise	51 min 56 sec	05 min 40 sec
Jumps Down	51 min 30 sec	05 min 53 sec
Jumps Up	50 min 40 sec	05 min 12 sec
No Jump	65 min 45 sec	06 min 01 sec
Peaks	61 min 31 sec	05 min 55 sec
Sequence Change	49 min 53 sec	06 min 41 sec
Darpa	185 min 49 sec	05 min 29 sec
Enron	01 min 47 sec	05 min 14 sec

**Tab. 5.2:** Überblick der Performanz in [min]

## 5.2 Ausblick

**todo:** Zudem sind beide Algorithmen für die statische Analyse ausgerichtet und könnten deswegen bspw. nur als Feature für den Netsimile verwendet werden. Er erkennt Ausreißer in Zeitreihen, kann erweitert werden um neue Merkmale als auch statischen Algorithmen, die als Merkmal dienen können. Zudem ist der Algorithmus performant und dynamisch.

Im Rahmen des Forschungsprojekts wurden drei Thematiken behandelt. Zunächst einmal wurde eine Möglichkeit ermittelt Zeitreihendaten in einen Graphen umzuwandeln. Im Anschluss wurden graphen-basierte Algorithmen auf die transformierten Zeitreihendaten angewendet, um diese Algorithmen im Anschluss hinsichtlich ihrer Eignung zur Ausreißer-Erkennung zu vergleichen.

**todo:** eventuell andere Distanzmaße zur Transformierung hinzuziehen? Da wir so auf den ersten Punkt genauer eingehen würden

Durch die erfolgreiche Transformation von Zeitreihendaten in Graphen kann der Vorgang ebenso für andere Datenkategorien herangezogen werden unter der Prämisse, dass Distanzen zwischen den einzelnen Elementen des Datensatzes gebildet werden können. So ist es im nächsten Schritt möglich bspw. Ausreißer in Finanzdaten oder Bilddaten zu erkennen.

Darüber hinaus nimmt der Netsimile **todo: bis hierhin habe ich es ausgeführt** Kommen wir nun zum Ausblick:

Interessant wären weitere Datensätze, auf denen die Algorithmen angewendet werden wie bspw. Finanzdaten oder auch Bilder. Die einzige Voraussetzung wäre hier die Bildung einer Distanz, die zwischen den einzelnen Elementen des Datensatzes gebildet werden müssten.

Zudem bringt der Netsimile unserer Meinung nach noch nicht alles mit. Zum einen gibt der Netsimile nur den Ausreißer-Graphen zurück. Zum anderen wird momentan der Graph erst dann berechnet, wenn dieser alle Kanten eines Zeitintervalls beinhaltet. Hier könnten Optimierungen folgen, die bspw. den Ausreißer-Graphen auf Knoten oder Kanten untersucht, die für den Ausreißerscore am meisten beigetragen haben. Zudem könnten man einen Weg suchen, um den Graphen iterativ vergrößern zu können, damit eventuell schon vor dem vollständigen Erstellen des Graphens herausgefunden werden kann, ob es sich um einen Ausreißer handelt.

**Aufschrieb** Der Netsimile Algorithmus wurde bisher nur auf Zeitreihendaten und Graphen angewendet. Interessant wären jedoch noch Bilder, Biologische Daten und andere Netzwerke. Die einzige Voraussetzung ist die Berechnung einer Distanz zwischen einzelnen Elementen in diesen Daten. Zudem gibt es viele statische Algorithmen, die als Feature dem Netsimile hinzugefügt werden können. Erkennt der Perculation Algorithmus bspw. Ausreißer-Typen wie Increase-noise, Jumpsdown, Jumpsup und Flatmiddle, so kann nach weiteren Algorithmen gesucht werden, die die anderen Ausreißer Typen erkennt. Zudem wird beim Netsimile Algorithmus lediglich der Graph zurückgegeben der als Ausreißer identifiziert wurde, nicht aber der Grund dafür. Hierfür könnten weitere Untersuchungen durchgeführt werden, wie bspw. die Analyse der Features, welches sich am meisten von den anderen unterscheiden hat oder einer anschließenden Analyse durch den Oddball Algorithmus, welche die Anomalien innerhalb des Graphens untersucht.

Des weiteren könnte eine allgemeine Forschung gestartet werden, welche untersucht, welche Features für spezifische Anwendungsgebiete geeignet sein könnten.

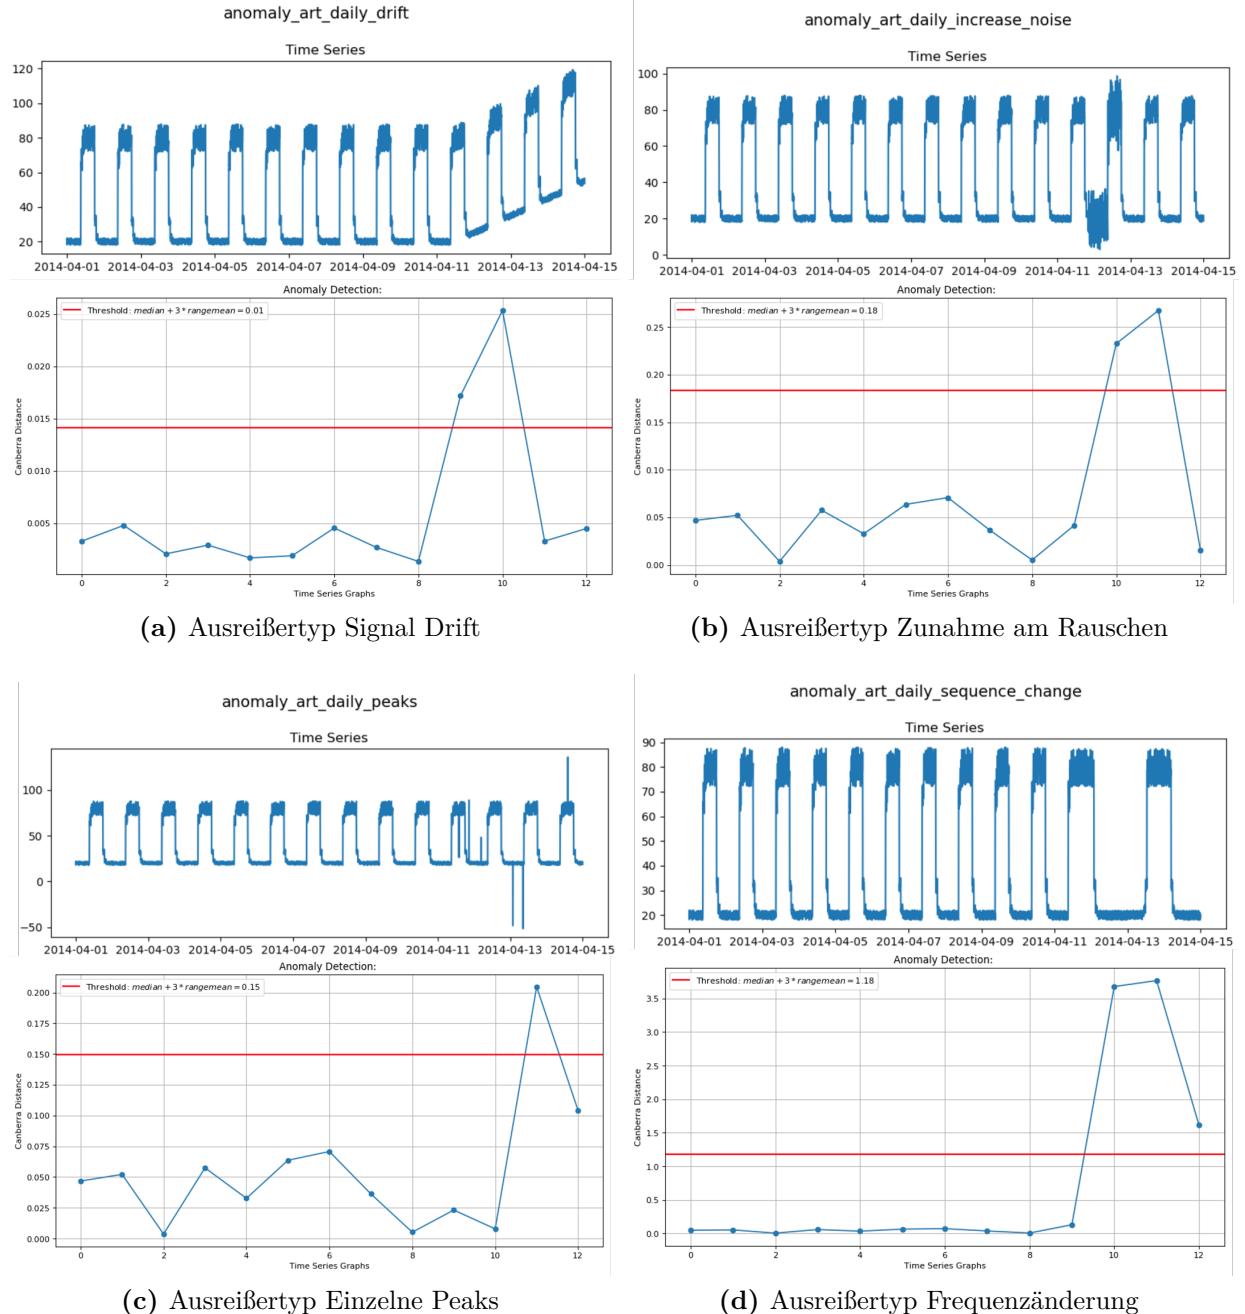
**todo:** Ausblick schreiben

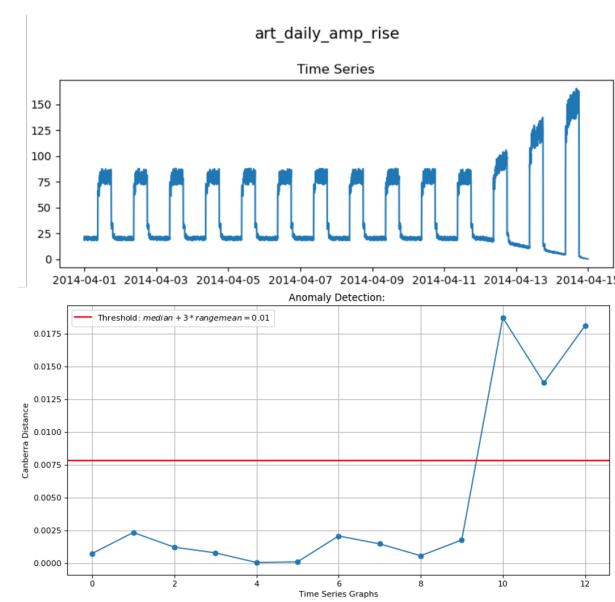
## A Netsimile

A.1 Eindimensionales Signal ursprüngliche Version

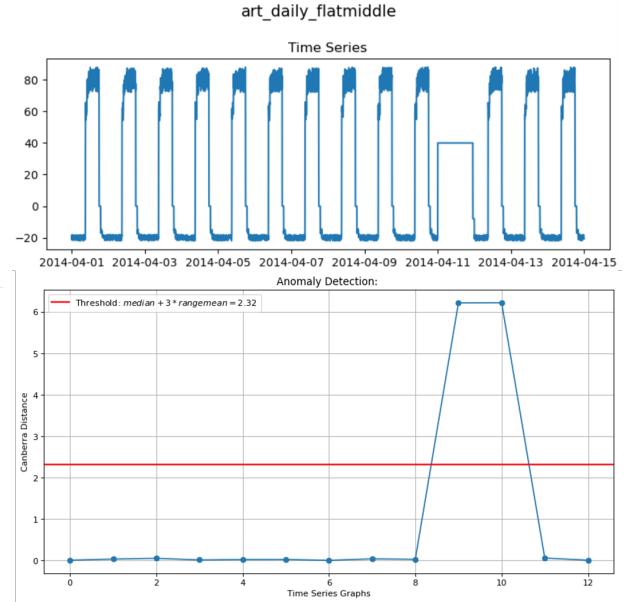
A.2 Eindimensionales Signal Optimierte Version

todo: Wrong picture for daily peaks. Change that the sixed element is not always an outlier

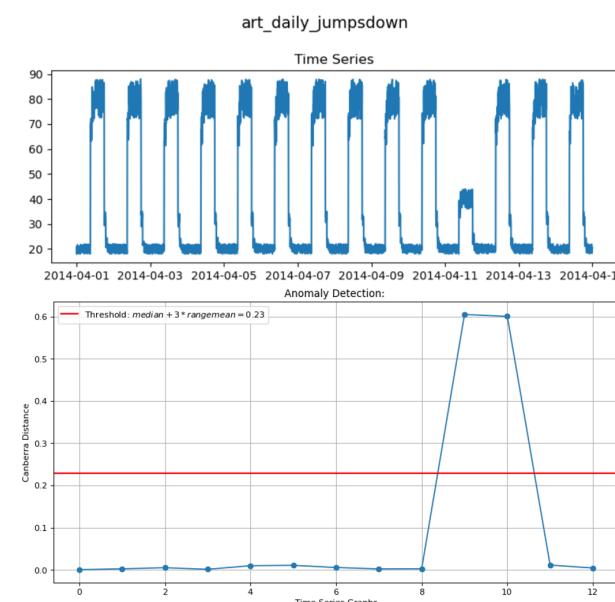




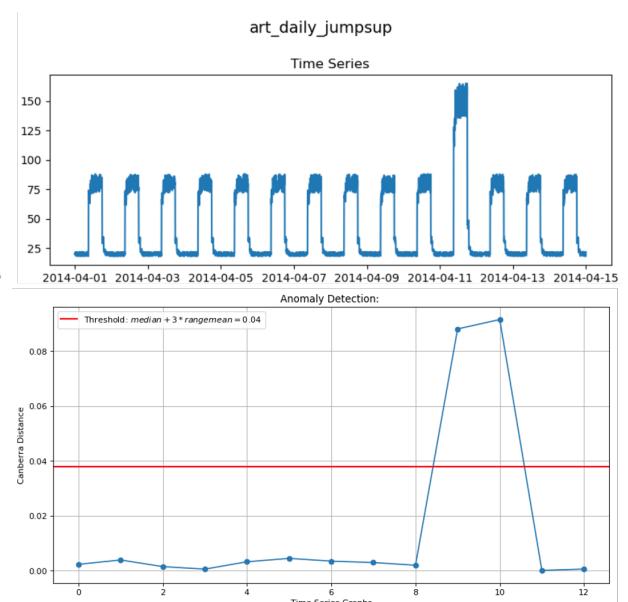
(e) Ausreißertyp Kontinuierliche Zunahme der Amplitude



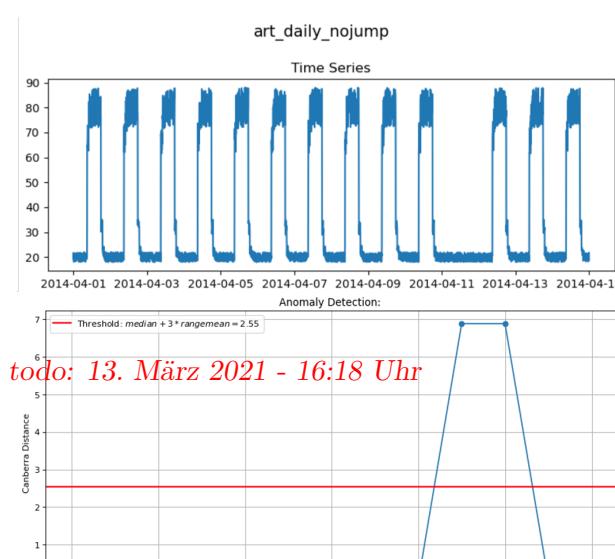
(f) Ausreißertyp Zyklus Aussetzer



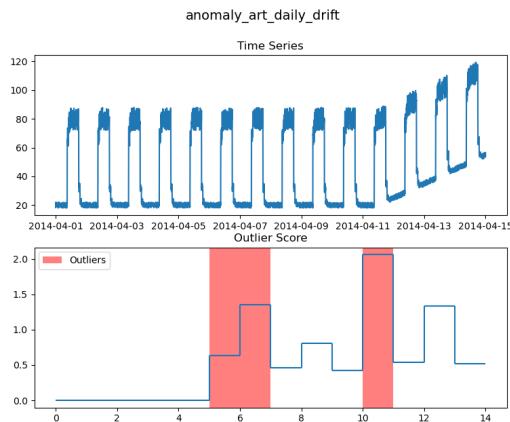
(g) Ausreißertyp Zyklus mit geringerer Amplitude



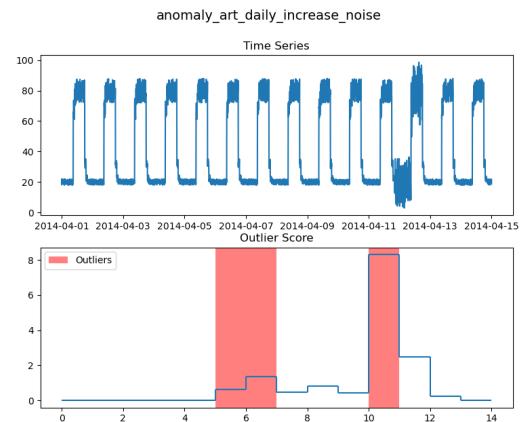
(h) Ausreißertyp Zyklus mit höherer Amplitude



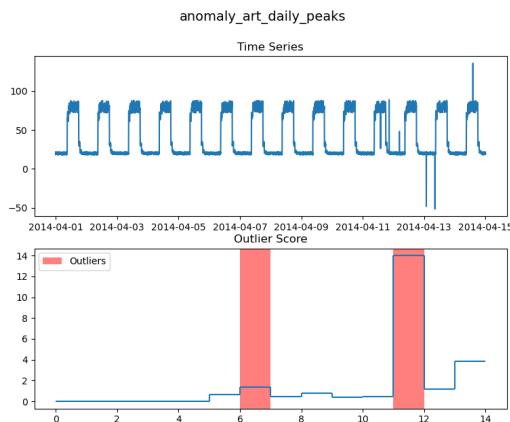
*todo: 13. März 2021 - 16:18 Uhr*



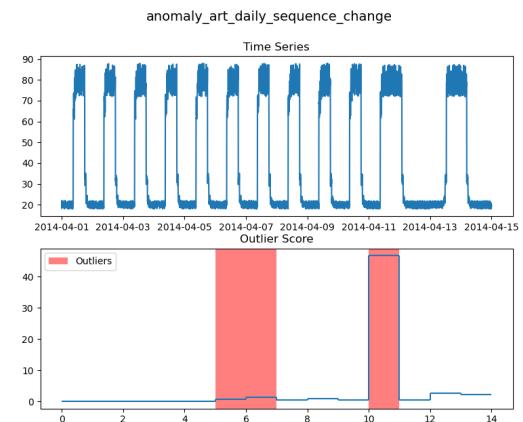
(a) Caption for sub-figure1



(b) Caption for sub-figure1



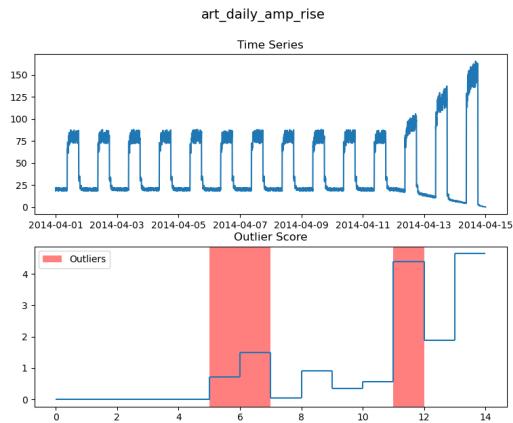
(c) Caption for sub-figure1



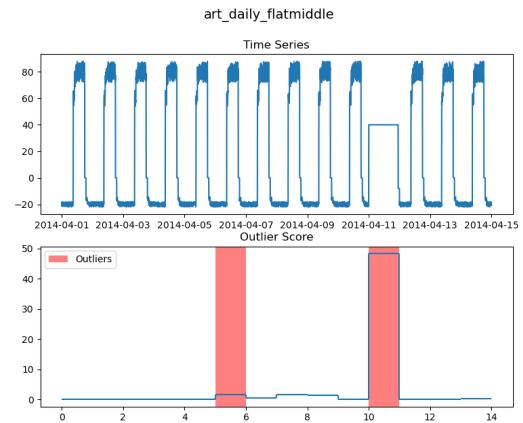
(d) Caption for sub-figure1

### A.3 Zweidimensionales Signal Optimierte Version

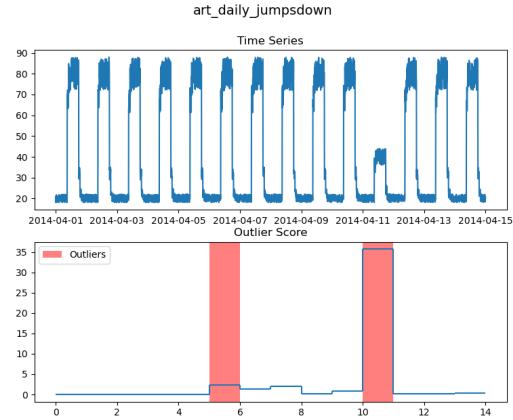
todo: Wrong picture for daily peaks. Change that the sixed element is not always an outlier



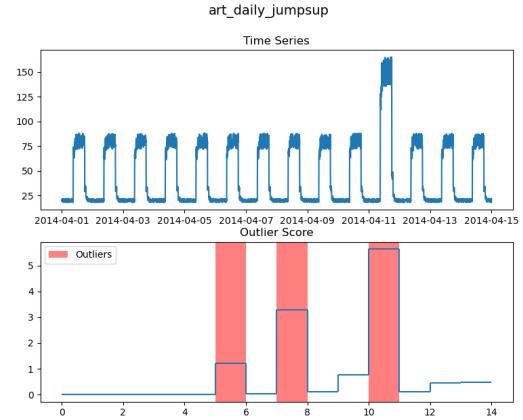
(e) Caption for sub-figure1



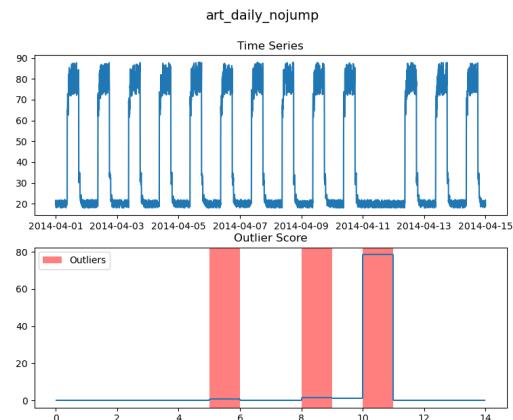
(f) Caption for sub-figure1



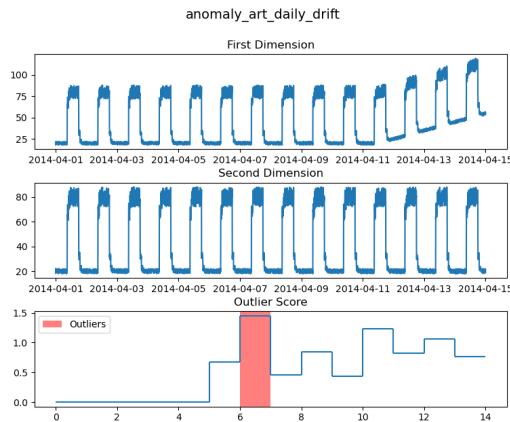
(g) Caption for sub-figure1



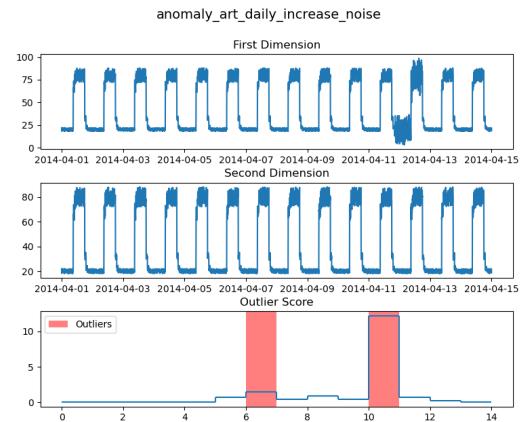
(h) Caption for sub-figure1



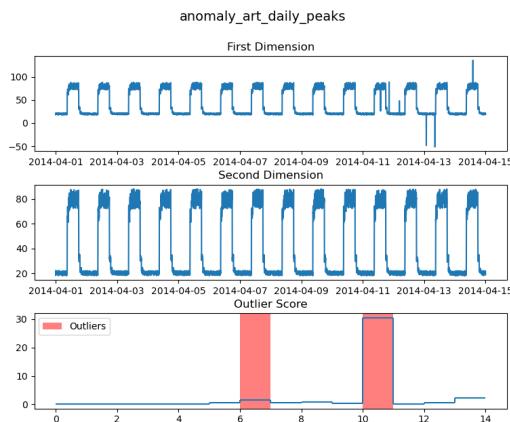
(i) Caption for sub-figure1



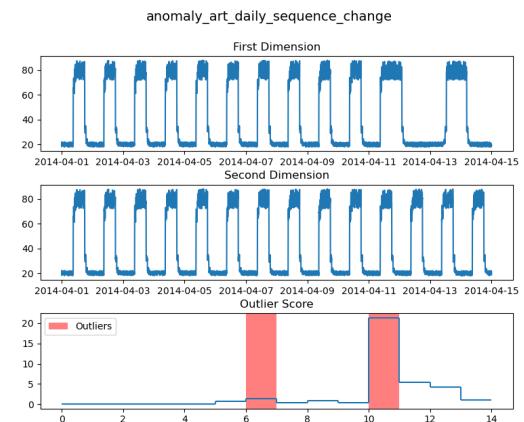
(a) Caption for sub-figure1



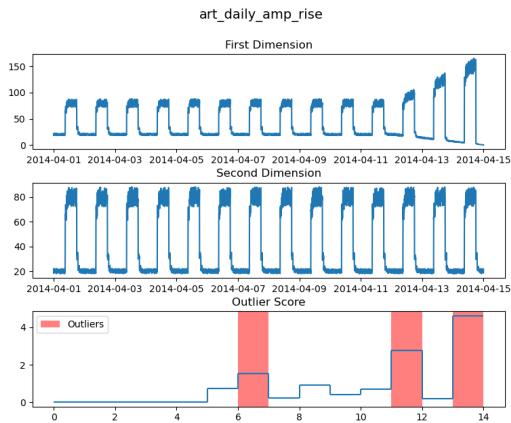
(b) Caption for sub-figure1



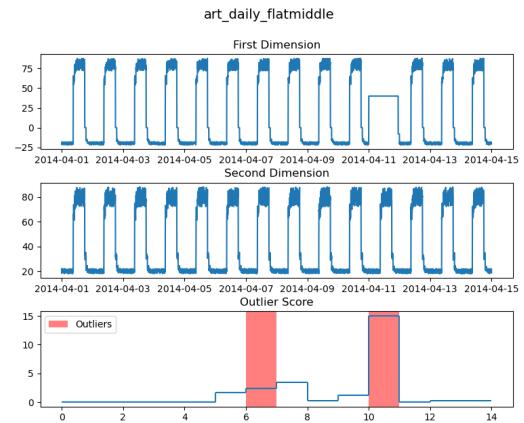
(c) Caption for sub-figure1



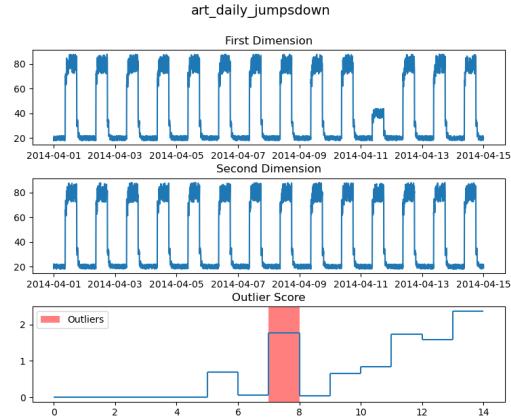
(d) Caption for sub-figure1



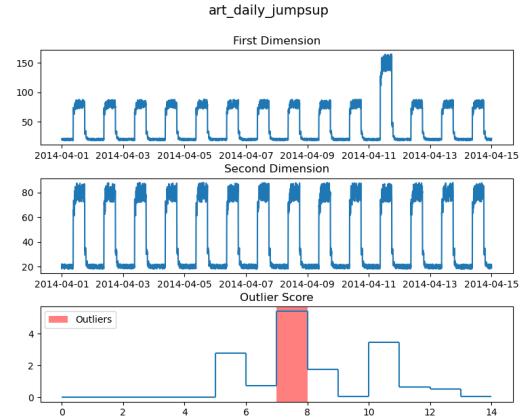
(e) Caption for sub-figure1



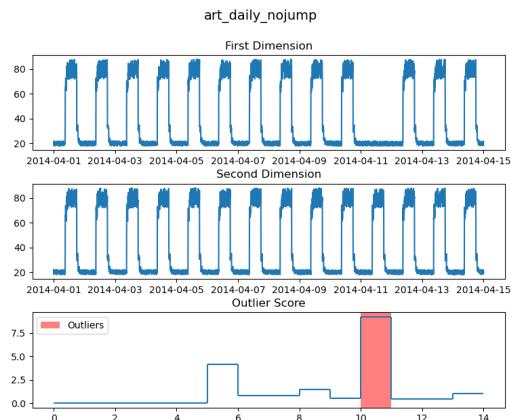
(f) Caption for sub-figure1



(g) Caption for sub-figure1

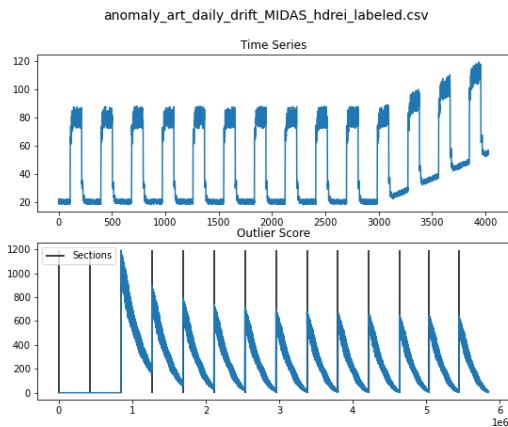


(h) Caption for sub-figure1

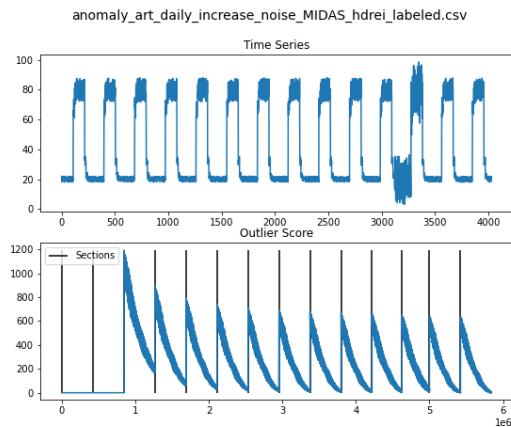


(i) Caption for sub-figure1

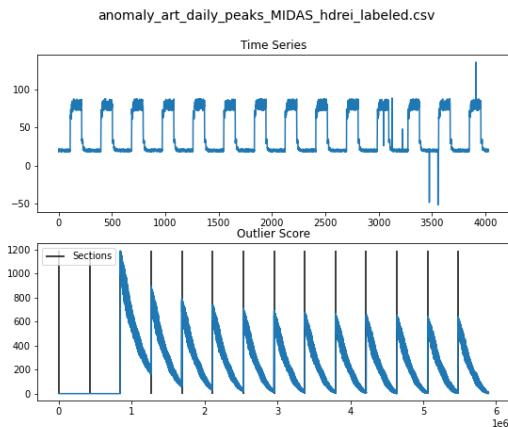
## B Midas



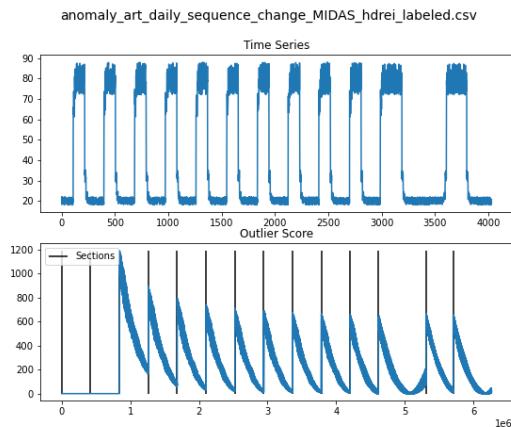
(a) Caption for sub-figure1



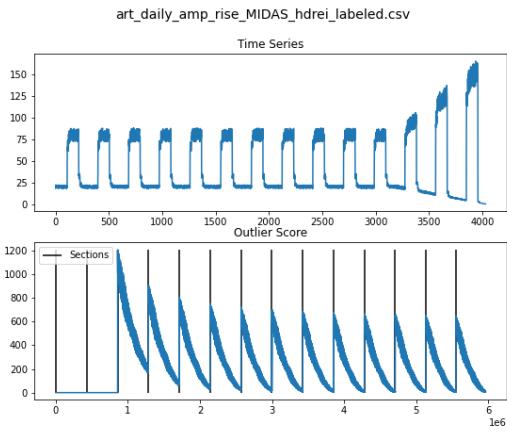
(b) Caption for sub-figure1



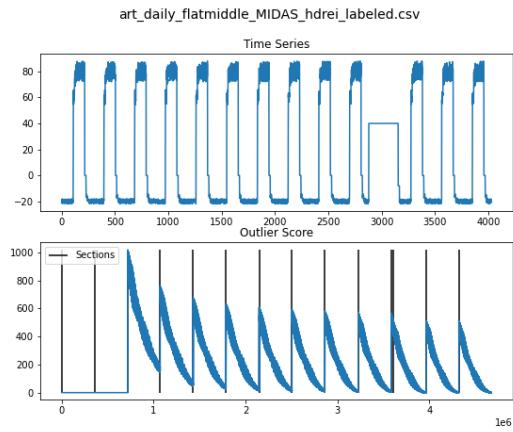
(c) Caption for sub-figure1



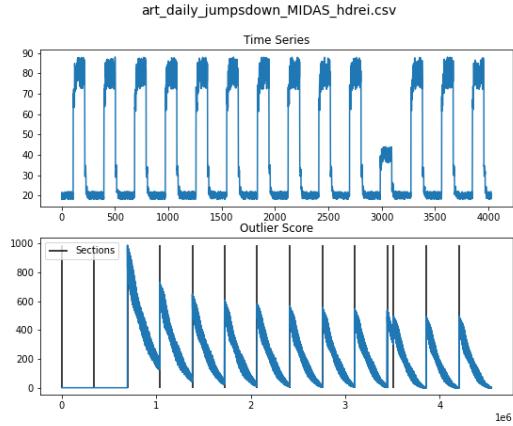
(d) Caption for sub-figure1



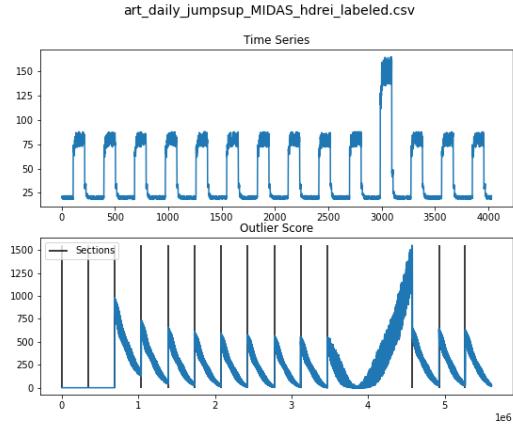
(e) Caption for sub-figure1



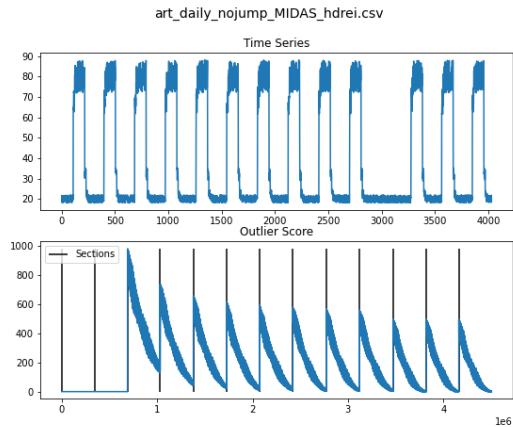
(f) Caption for sub-figure1



(g) Caption for sub-figure1



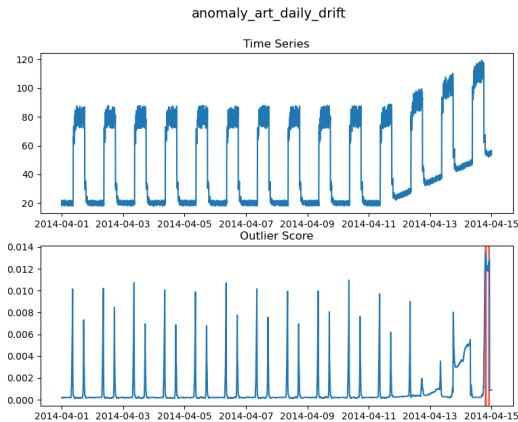
(h) Caption for sub-figure1



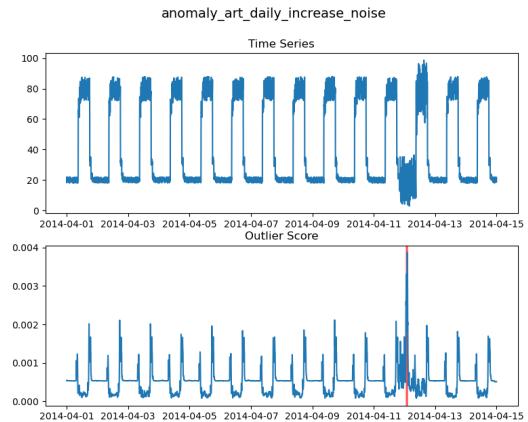
(i) Caption for sub-figure1

## C Isomap

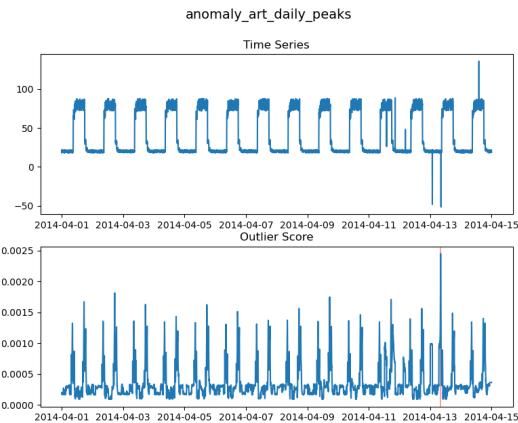
### C.1 Eindimensionales Signal



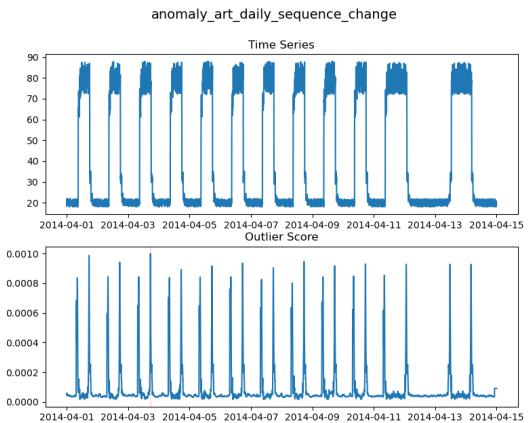
(a) Caption for sub-figure1



(b) Caption for sub-figure1

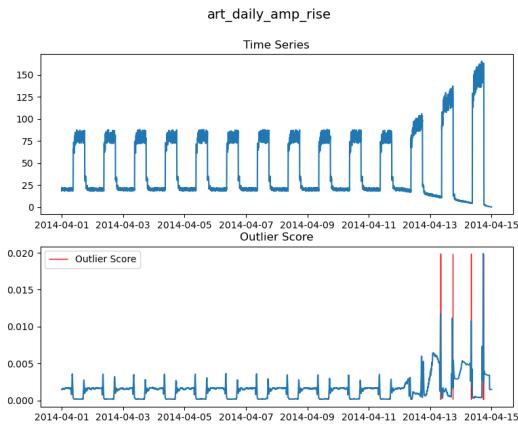


(c) Caption for sub-figure1

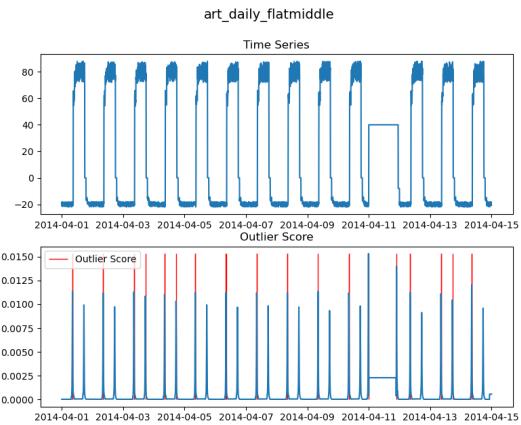


(d) Caption for sub-figure1

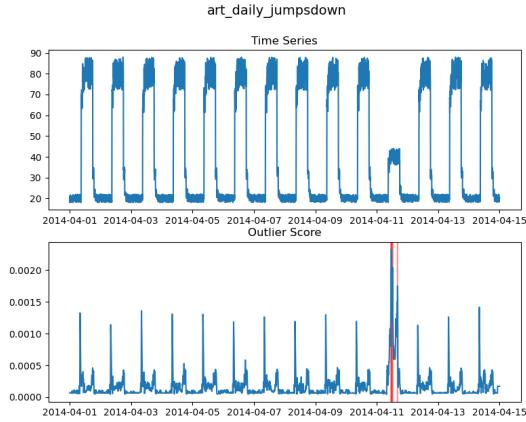
todo: In einigen Bildern fehlt die Legende. Vielleicht noch ein Paar bessere Ergebnisse zu erzielen



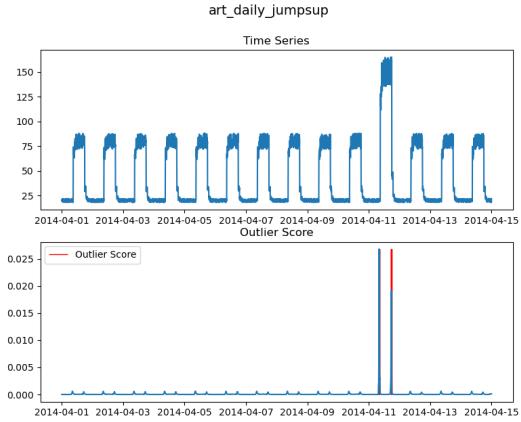
(e) Caption for sub-figure1



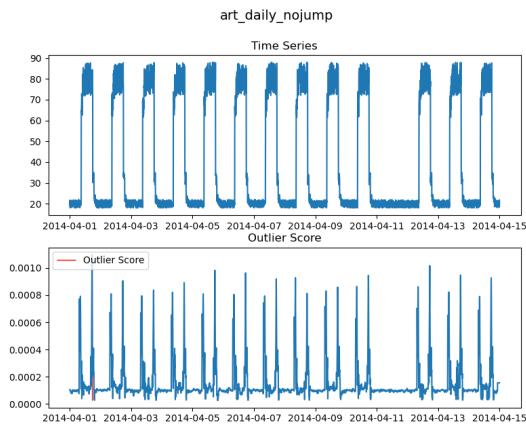
(f) Caption for sub-figure1



(g) Caption for sub-figure1



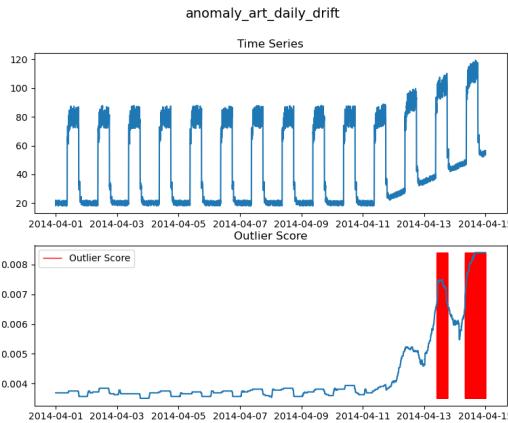
(h) Caption for sub-figure1



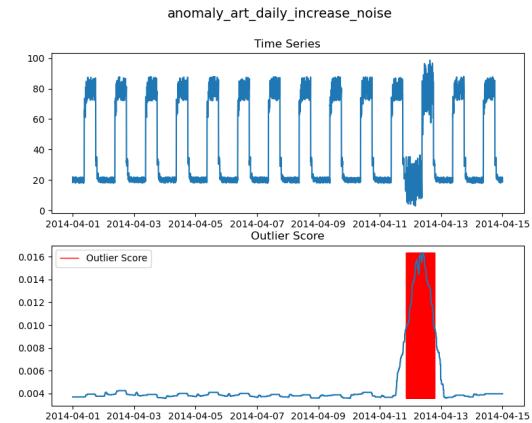
(i) Caption for sub-figure1

## D Perculation

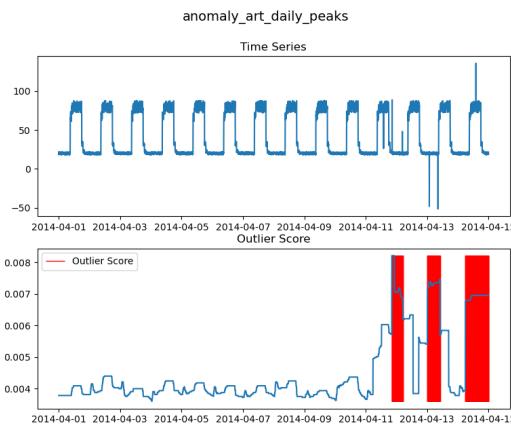
### D.1 Sliding Window



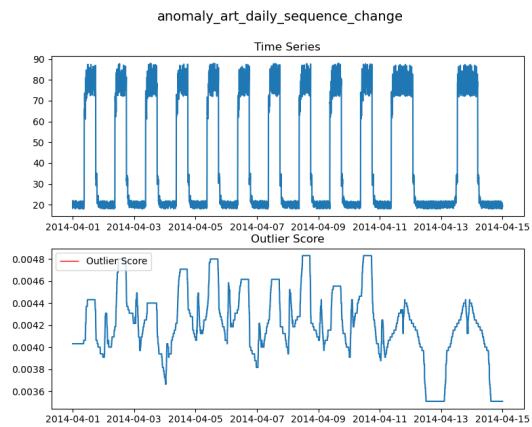
(a) Caption for sub-figure1



(b) Caption for sub-figure1

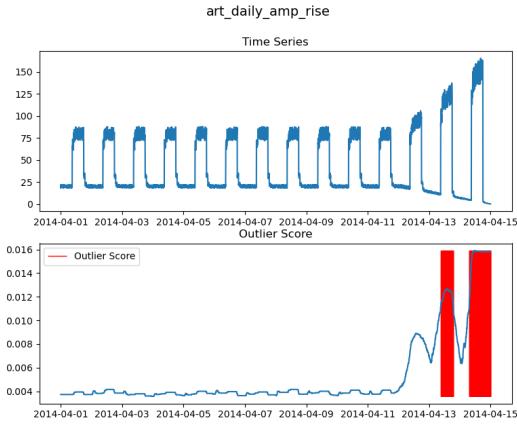


(c) Caption for sub-figure1

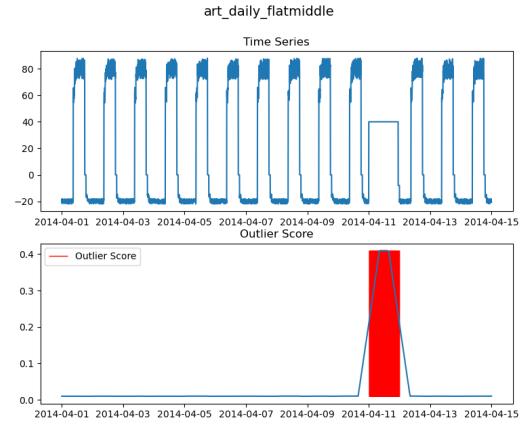


(d) Caption for sub-figure1

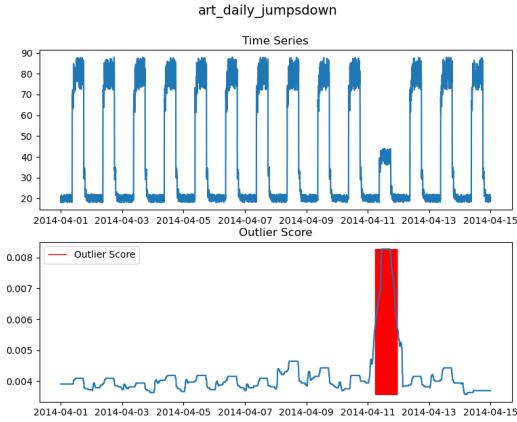
todo: Nim mir nicht sicher ob ich das ohne sliding window auch noch einfÃ¼gen soll. Vielleicht kann ich oben ja einmal einen Vergleich mit sliding window und ohne sliding window rein machen



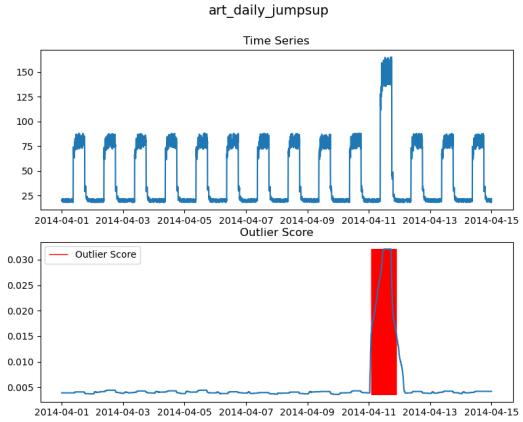
(e) Caption for sub-figure1



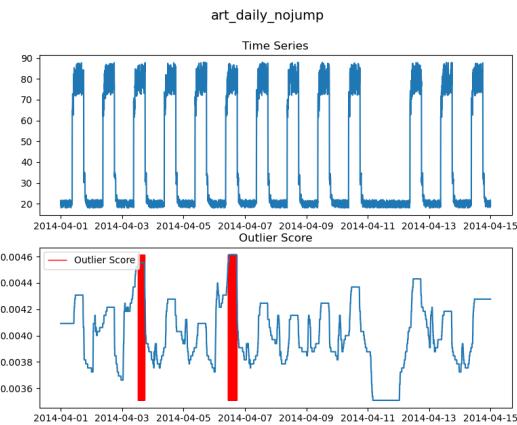
(f) Caption for sub-figure1



(g) Caption for sub-figure1



(h) Caption for sub-figure1



(i) Caption for sub-figure1

## Literaturverzeichnis

- [1] Amil, P., Almeira, N. and Masoller, C. [2019], ‘Outlier mining methods based on graph structure analysis’, *Frontiers in Physics* **7**, 194.  
**URL:** <https://www.frontiersin.org/article/10.3389/fphy.2019.00194>
- [2] Berlingerio, M., Koutra, D., Eliassi-Rad, T. and Faloutsos, C. [2012], ‘Netsimile: A scalable approach to size-independent network similarity’, *CoRR abs/1209.2684*.  
**URL:** <http://arxiv.org/abs/1209.2684>
- [3] Bhatia, S., Hooi, B., Yoon, M., Shin, K. and Faloutsos, C. [2020], Midas: Microcluster-based detector of anomalies in edge streams, in ‘AAAI 2020 : The Thirty-Fourth AAAI Conference on Artificial Intelligence’.
- [4] Chandola, V., Banerjee, A. and Kumar, V. [2012], ‘Anomaly detection for discrete sequences: A survey’, *IEEE Transactions on Knowledge and Data Engineering* **24**(5), 823–839.
- [5] Cheng, H., Tan, P., Potter, C. and Klooster, S. [2008], A robust graph-based algorithm for detection and characterization of anomalies in noisy multivariate time series, in ‘2008 IEEE International Conference on Data Mining Workshops’, pp. 349–358.
- [6] Cormode, G. and Muthukrishnan, S. [2004], An improved data stream summary: The count-min sketch and its applications., pp. 29–38.
- [7] Eswaran, D. and Faloutsos, C. [2018], Sedanspot: Detecting anomalies in edge streams, pp. 953–958. Die Supplementary-Dokumentation wurde ebenfalls genutzt.
- [8] Fernández, M.-L. and Valiente, G. [2001], ‘A graph distance metric combining maximum common subgraph and minimum common supergraph’, *Pattern Recogn. Lett.* **22**(6??), 753?758.  
**URL:** [https://doi.org/10.1016/S0167-8655\(01\)00017-4](https://doi.org/10.1016/S0167-8655(01)00017-4)
- [9] Hawkins, S., He, H., Williams, G. and Baxter, R. [2002], Outlier detection using replicator neural networks, in Y. Kambayashi, W. Winiwarter and M. Arikawa, eds, ‘Data Warehousing and Knowledge Discovery’, Springer Berlin Heidelberg, Berlin, Heidelberg, pp. 170–180.
- [10] Li, G., Semerci, M., Yener, B. and Zaki, M. [2012], ‘Graph classification via topological and label attributes’.
- [11] Lippmann, R., Haines, J., Fried, D., Korba, J. and Das, K. [2000], Analysis and results of the 1999 darpa off-line intrusion detection evaluation, pp. 162–182.
- [12] Munir, M., Siddiqui, S. A., Dengel, A. and Ahmed, S. [2019], ‘Deepant: A deep learning approach for unsupervised anomaly detection in time series’, *IEEE Access* **7**, 1991–2005.

- [13] Rahmani, A., Afra, S., Zarour, O., Addam, O., Koochakzadeh, N., Kianmehr, K., Alhajj, R. and Rokne, J. [2014], ‘Graph-based approach for outlier detection in sequential data and its application on stock market and weather data’, *Knowledge-Based Systems* **61**, 89–97.  
**URL:** <https://www.sciencedirect.com/science/article/pii/S0950705114000574>
- [14] Ranshous, S., Harenberg, S., Sharma, K. and Samatova, N. [2016], A scalable approach for outlier detection in edge streams using sketch-based approximations, pp. 189–197.
- [15] Shin, K., Hooi, B., Kim, J. and Faloutsos, C. [2017], Densealert: Incremental dense-subtensor detection in tensor streams, pp. 1057–1066.
- [16] Tenenbaum, J. B., Silva, V. d. and Langford, J. C. [2000], ‘A global geometric framework for nonlinear dimensionality reduction’, *Science* **290**(5500), 2319–2323.  
**URL:** <https://science.sciencemag.org/content/290/5500/2319>
- [17] Uzun, Kielman, E. [2020], ‘Anomalie-erkennung in graphen’.
- [18] Yu, W., Aggarwal, C. C., Ma, S. and Wang, H. [2013], On anomalous hotspot discovery in graph streams, in ‘2013 IEEE 13th International Conference on Data Mining’, pp. 1271–1276.
- [19] Zager, L. and Verghese, G. [2008], ‘Graph similarity scoring and matching’, *Applied Mathematics Letters* **21**, 86–94.